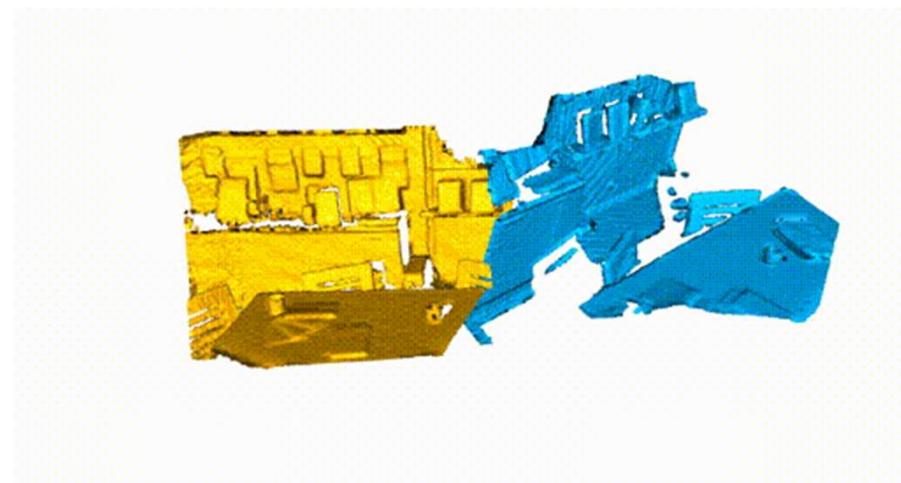


# Procesamiento Geométrico y Análisis de Formas

Ivan Sipiran

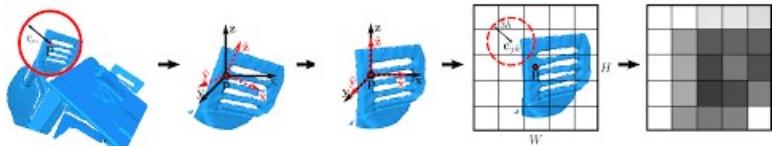
# Global Registration

- ICP requiere que exista un alineamiento inicial bueno
- A veces esa condición no es fácil de obtener
- Necesitamos otro tipo de algoritmo para hacer “global registration”

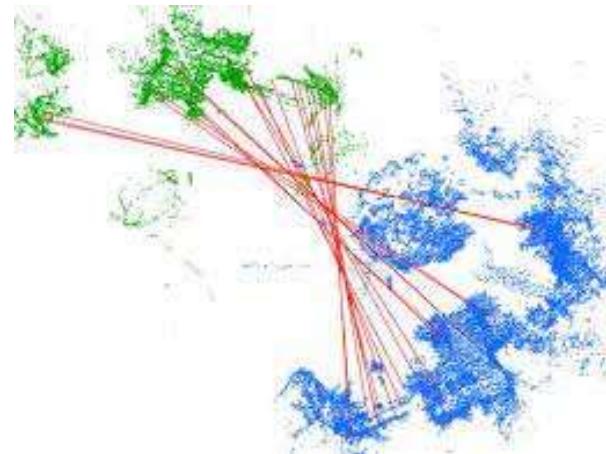


# Global Registration Pipeline

- Es necesario contar con más información que solo la nube de puntos
- El problema específico es: cómo encontrar buenas correspondencias sin asumir cercanía de puntos.
- Solución: búsquedas en espacios característicos

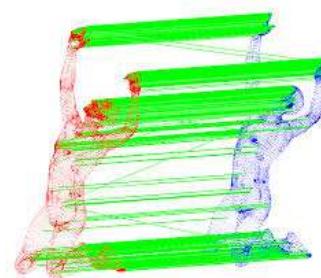
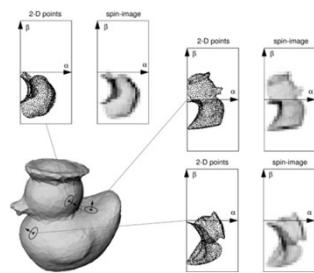
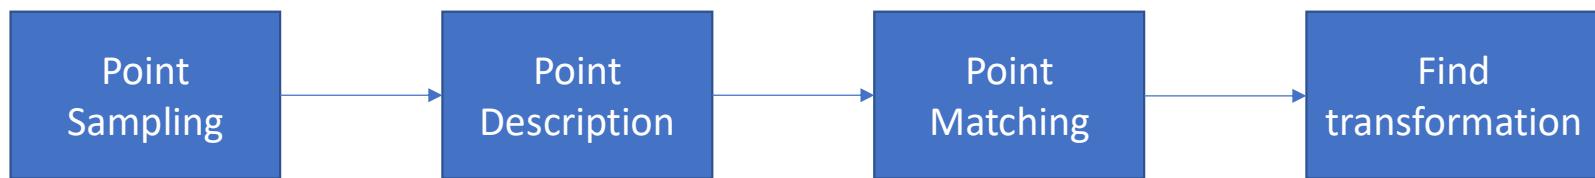


Point description



Point matching

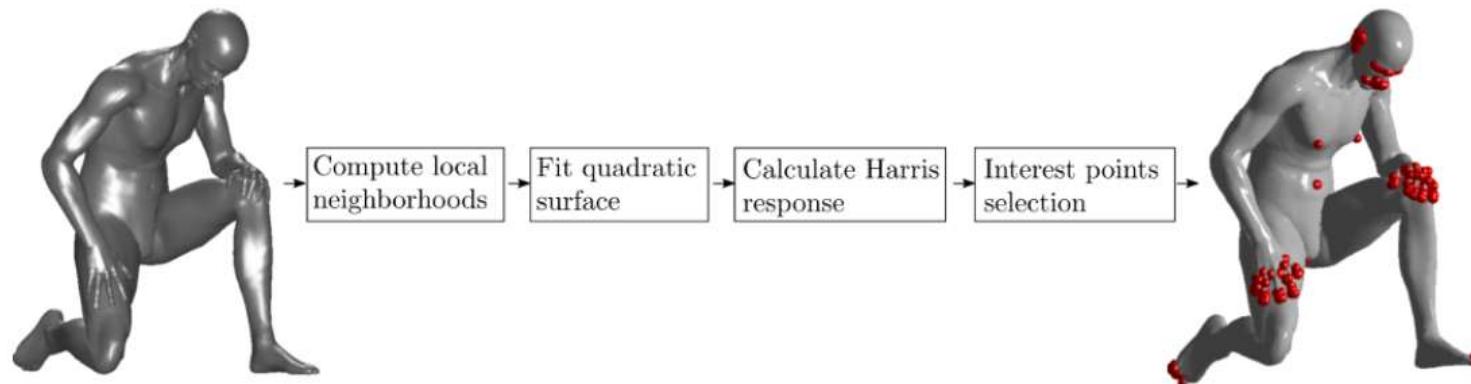
# Global Registration Pipeline



# Point Sampling

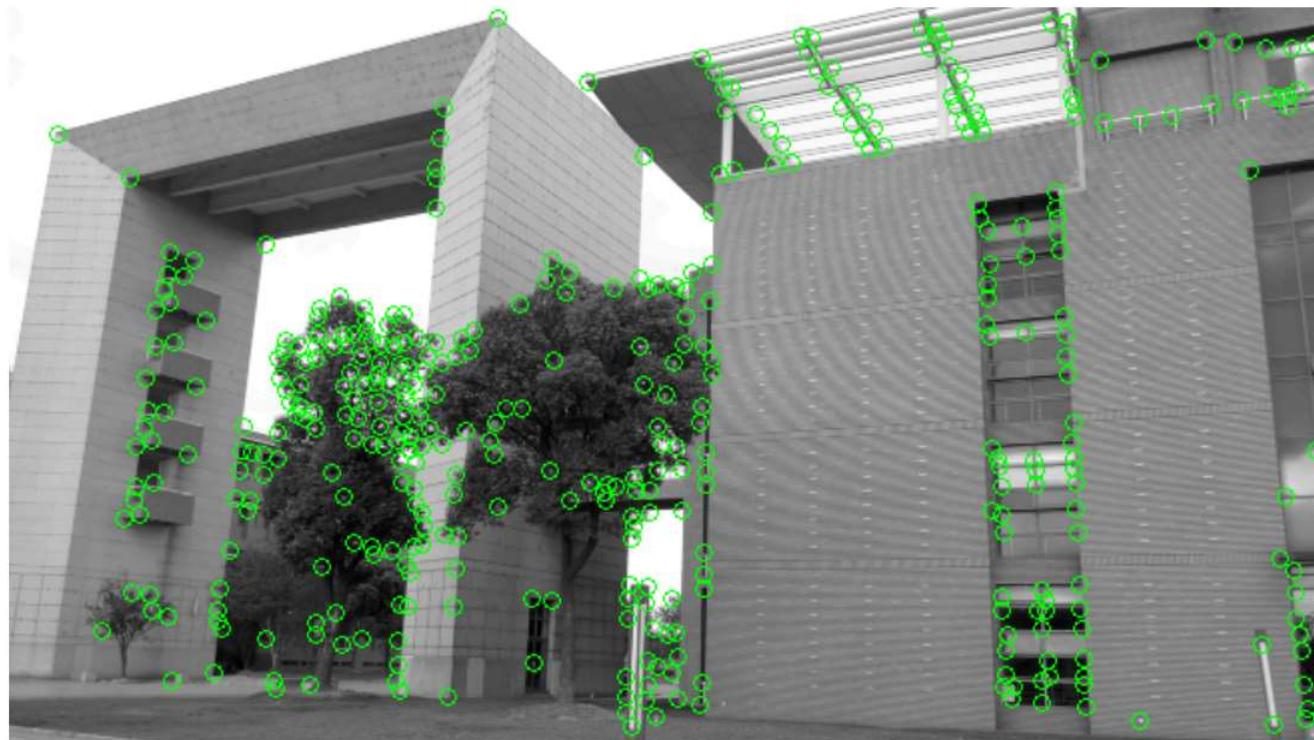
# Algoritmo Harris 3D

- Detectar puntos de interés en geometría 3D
  - Funciona sobre mallas y sobre nubes de puntos
- Pipeline



# Algoritmo Harris 3D

- Existe un algoritmo para detectar puntos de interés en imágenes



# Algoritmo Harris 3D

- Definimos  $I(x, y)$  una imagen como una función
- Para detectar una esquina, hay que evaluar los cambios de una vecindad consigo misma
- Función de correlación

$$e(x, y) = \sum_{x_i, y_i} W(x_i, y_i)[I(x_i + \Delta x, y_i + \Delta y) - I(x_i, y_i)]^2$$

- Se usa una función Gaussiana para ponderar la vecindad.

# Algoritmo Harris 3D

- Usando una expansión de Taylor, la función de auto-correlación queda

$$\begin{aligned} e(x, y) &= \vec{S} \begin{bmatrix} \sum_{x_i, y_i} W \cdot I_x^2 & \sum_{x_i, y_i} W \cdot I_x \cdot I_y \\ \sum_{x_i, y_i} W \cdot I_x \cdot I_y & \sum_{x_i, y_i} W \cdot I_y^2 \end{bmatrix} \vec{S}^T \\ &= \vec{S} E(x, y) \vec{S}^T \end{aligned}$$

- Donde  $\vec{S} = [\Delta x \ \Delta y]$  es un vector de desplazamiento.  $I_x, I_y$  son las derivadas parciales de la imagen en los ejes coordenados
- Estructura local de la imagen queda determinada por los valores propios de la matriz

$$h(x, y) = \det(E) - k(\text{tr}(E))^2$$

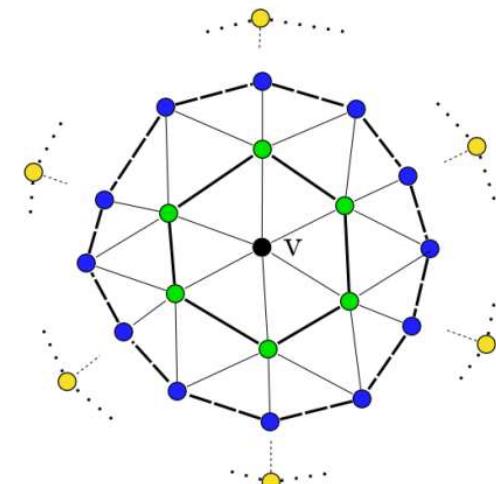
# Algoritmo Harris 3D

- Extensión para geometría 3D no es trivial
  - Cómo se definen vecindades?
  - Cómo se calculan derivadas?
- Para mallas, vecindades adaptivas

$$ring_k(v) = \{w \in V' \text{ such that } |shortest\_path(v, w)| = k\}$$

$$d_{ring}(v, ring_k(v)) = \max_{w \in ring_k(v)} \|v - w\|_2$$

$$\begin{aligned} radius_v = \{k \in \mathbb{N} \text{ such that } d_{ring}(v, ring_k(v)) \geq \delta \text{ and} \\ d_{ring}(v, ring_{k-1}(v)) < \delta\} \end{aligned}$$



# Algoritmo Harris 3D

- Cómo lidiamos con las derivadas?
- Fitting de una superficie cuadrática en punto  $v$ 
  - Trasladar la vecindad al origen
  - Normalizar orientación con análisis de componentes principales
  - Ajustar una superficie cuadrática

$$z = f(x, y) = \frac{p_1}{2}x^2 + p_2xy + \frac{p_3}{2}y^2 + p_4x + p_5y + p_6$$

- Función  $f(x, y)$  es similar a una imagen!

# Algoritmo Harris 3D

- Calcular la matriz de Harris
- Para manejar cambios locales en la geometría: suavizamiento

$$A = \frac{1}{2\sigma^4\pi} \int_{\mathbb{R}^2} e^{\frac{-(x^2+y^2)}{2\sigma^2}} \cdot \left( \frac{\partial f(x, y)}{\partial x} \right)^2 dx dy$$

$$B = \frac{1}{2\sigma^4\pi} \int_{\mathbb{R}^2} e^{\frac{-(x^2+y^2)}{2\sigma^2}} \cdot \left( \frac{\partial f(x, y)}{\partial y} \right)^2 dx dy$$

$$C = \frac{1}{2\sigma^4\pi} \int_{\mathbb{R}^2} e^{\frac{-(x^2+y^2)}{2\sigma^2}} \cdot \left( \frac{\partial f(x, y)}{\partial x} \right) \left( \frac{\partial f(x, y)}{\partial y} \right) dx dy$$

# Algoritmo Harris 3D

- Al evaluar las integrales en el continuo, obtenemos
- Se forma matriz de auto-correlación

$$E = \begin{pmatrix} A & C \\ C & B \end{pmatrix}$$

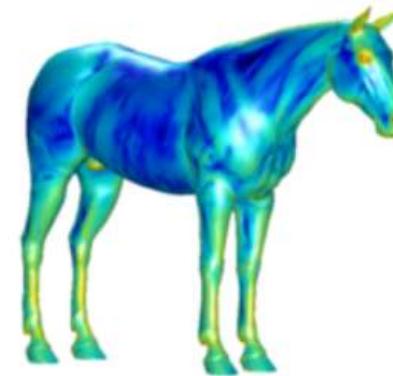
$$A = \frac{p_4^2}{\sigma^2} + p_1^2 + p_2^2$$

$$B = \frac{p_5^2}{\sigma^2} + p_2^2 + p_3^2$$

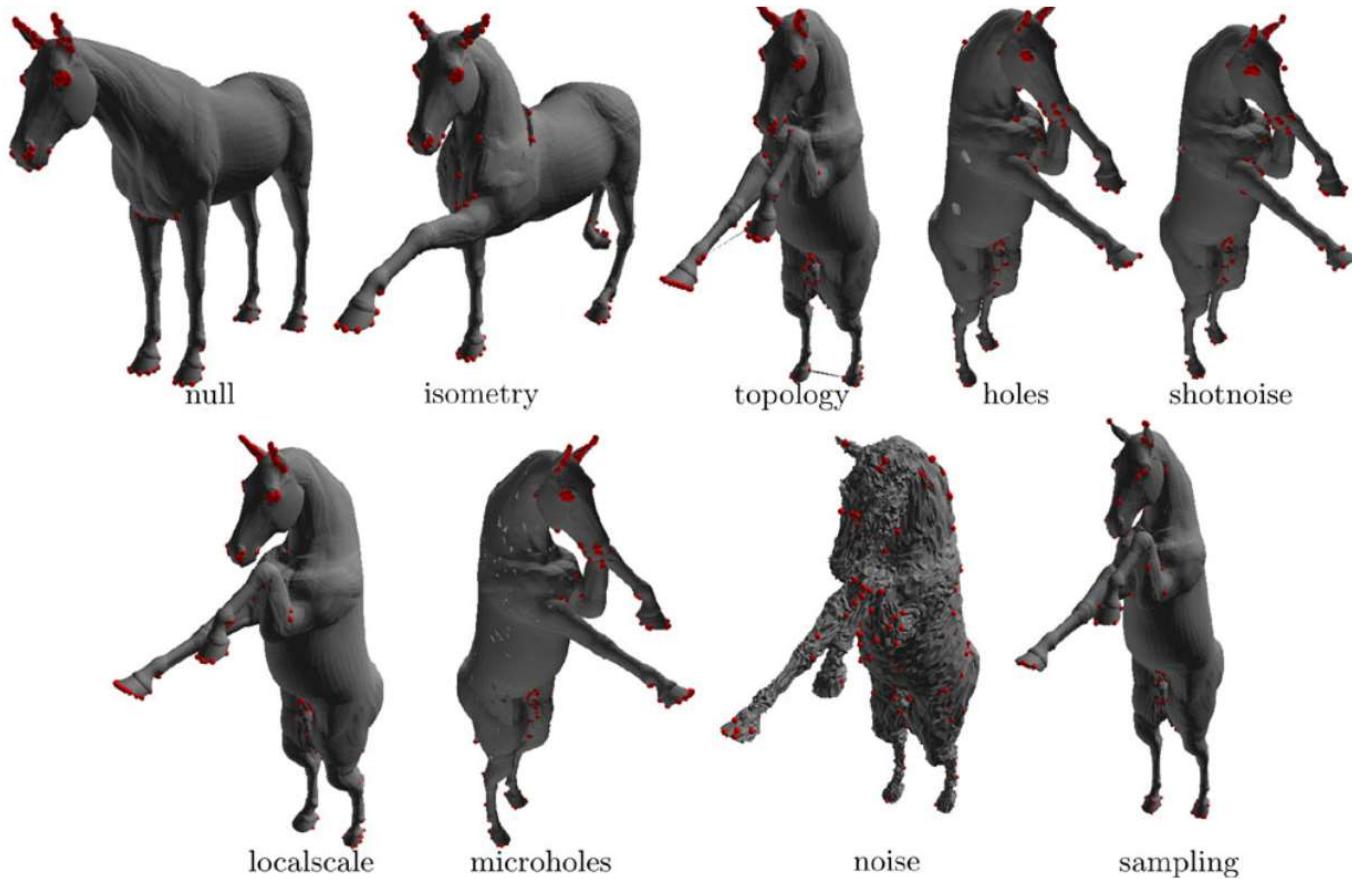
$$C = \frac{p_4 p_5}{\sigma^2} + p_1 p_2 + p_2 p_3$$

- Evaluamos el operador Harris y seleccionamos los puntos con la respuesta más alta.

# Algoritmo Harris 3D



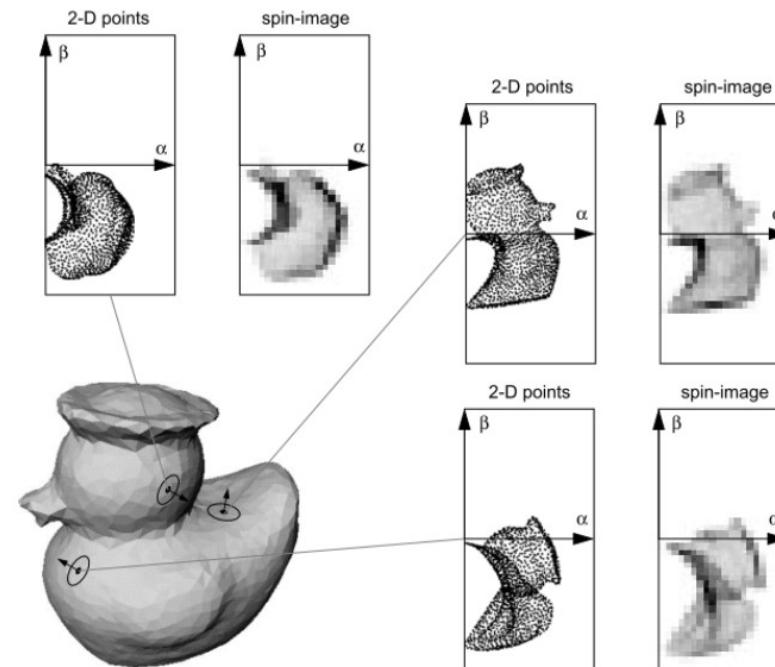
# Algoritmo Harris 3D



# Point Descriptor

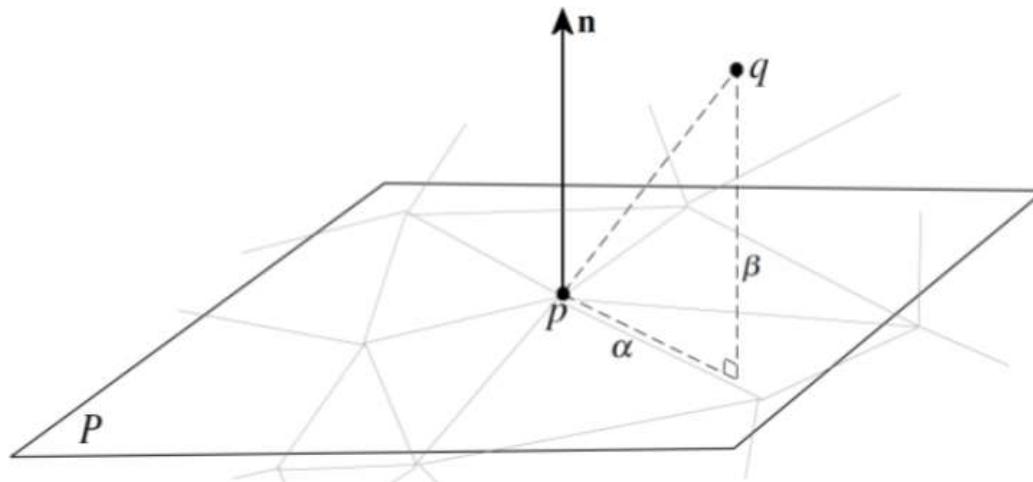
# Spin Images

- Se basa en la distribución de puntos sobre la superficie de un objeto



# Spin Images

- Se construye una base local
  - Punto  $p$
  - Normal  $\mathbf{n}$
  - Plano tangente  $P$  perpendicular a  $\mathbf{n}$



# Spin Images

- Cualquier punto  $q$  puede ser representado en esta base

$$S_O : \mathbb{R}^3 \rightarrow \mathbb{R}^2$$

$$S_O(q) \rightarrow (\alpha, \beta) = (\sqrt{\|q - p\|^2 - (\vec{n} \cdot (q - p))^2}, \vec{n} \cdot (q - p))$$

- El punto  $q$  cae en la coordenada  $(\alpha, \beta)$  de la imagen formada por la base local

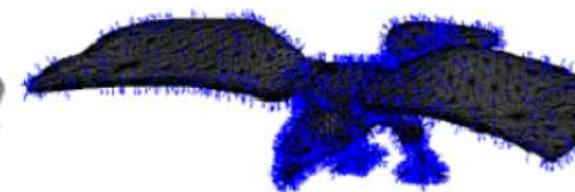
$$i = \left\lfloor \frac{\frac{W*bin}{2} - \beta}{bin} \right\rfloor$$

$$j = \left\lfloor \frac{\alpha}{bin} \right\rfloor$$

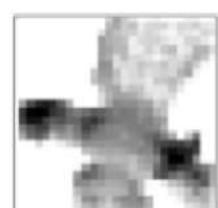
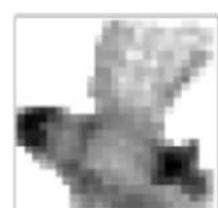
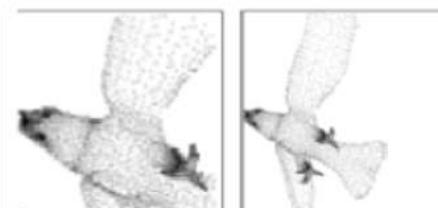
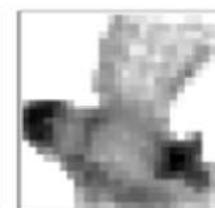
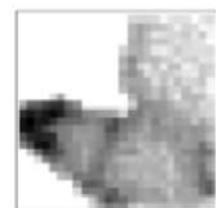
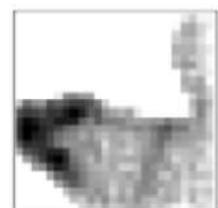
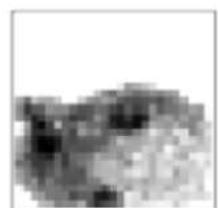
# Spin Images



(a)



(b)



# Point Matching

# Spin Images - Matching

- Dadas dos imágenes spin con N bins, computamos la correlación cruzada

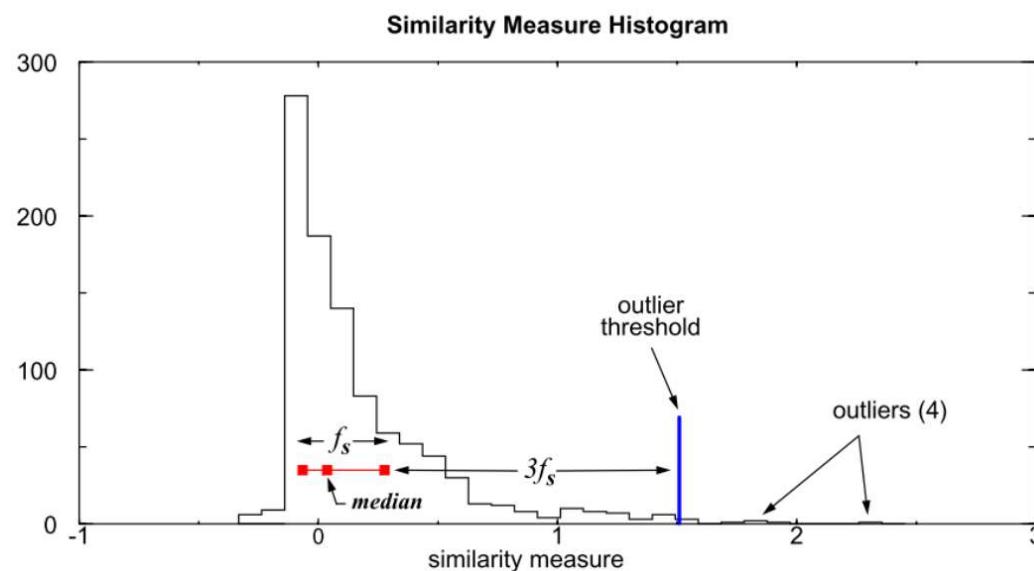
$$R(P, Q) = \frac{N \sum p_i q_i - \sum p_i \sum q_i}{\sqrt{(N \sum p_i^2 - (\sum p_i)^2)(N \sum q_i^2 - (\sum q_i)^2)}}$$

- La similitud toma en cuenta la varianza para evitar la dependencia a la densidad

$$C(P, Q) = (\operatorname{atanh}(R(P, Q)))^2 - \lambda \left( \frac{1}{N-3} \right)$$

# Spin Images - Matching

- Computar similitud entre spin images de puntos sampleados
- Solo es necesario un conjunto de correspondencias con los valores más altos de correlación



# Spin Images - Matching

- Filtrado de correspondencias
    - Correspondencias con similitud menor que la mitad de la máxima similitud
    - Dadas dos correspondencias  $C_1 = (s_1, m_1)$  y  $C_2 = (s_2, m_2)$ , la consistencia geométrica se define como
- $$d_{gc}(C_1, C_2) = 2 \frac{\|S_{m_2}(m_1) - S_{s_2}(s_1)\|}{\|S_{m_2}(m_1) + S_{s_2}(s_1)\|}$$
- $$D_{gc}(C_1, C_2) = \max(d_{gc}(C_1, C_2), d_{gc}(C_2, C_1))$$
- Consistencia involucra posición y normales
  - $D_{gc}$  es pequeño cuando hay consistencia
  - Descartar correspondencias que no son consistentes con al menos un cuarto de la lista de correspondencias.

# Finding Transformation

# Computar transformación

- Se define una medida de grupo de correspondencias

$$w_{gc}(C_1, C_2) = \frac{d_{gc}(C_1, C_2)}{1 - \exp(-(\|S_{m_2}(m_1)\| + \|S_{s_2}(s_1)\|)/2)}$$

$$W_{gc}(C_1, C_2) = \max(w_{gc}(C_1, C_2), w_{gc}(C_2, C_1))$$

- Y una medida entre una correspondencia y un grupo

$$W_{gc}(C, \{C_1, C_2, \dots, C_n\}) = \max_i(W_{gc}(C, C_i))$$

# Computar transformación

- Para cada correspondencia, se inicializa un grupo  $G_i = \{C_i\}$
- Encontrar una correspondencia que minimice  $W_{gc}(C_j, G_i)$ . Si esta métrica está por debajo de un umbral, agrandar el grupo  $G_i = G_i \cup \{C_j\}$
- Continuar hasta que no hayan más correspondencias para añadir

# Computar transformación

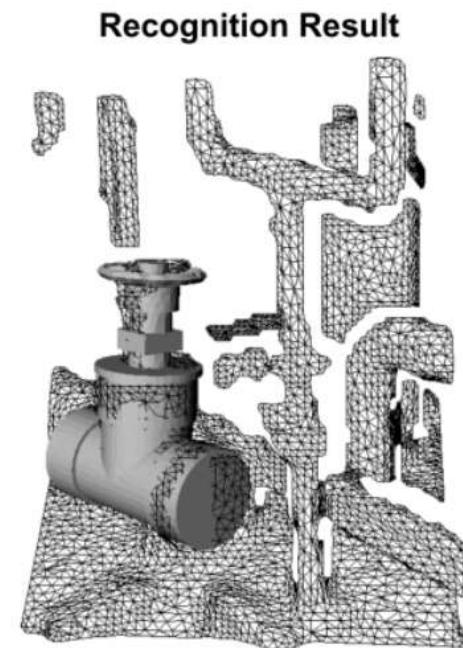
- Para cada grupo de correspondencias, computar una transformación rígida  $T$  que minimice el error

$$E_T = \min_T \sum \|s_i - T(m_i)\|^2$$

- $T$  consiste de una matriz  $R$  y un vector de traslación  $t$

# Computar transformación

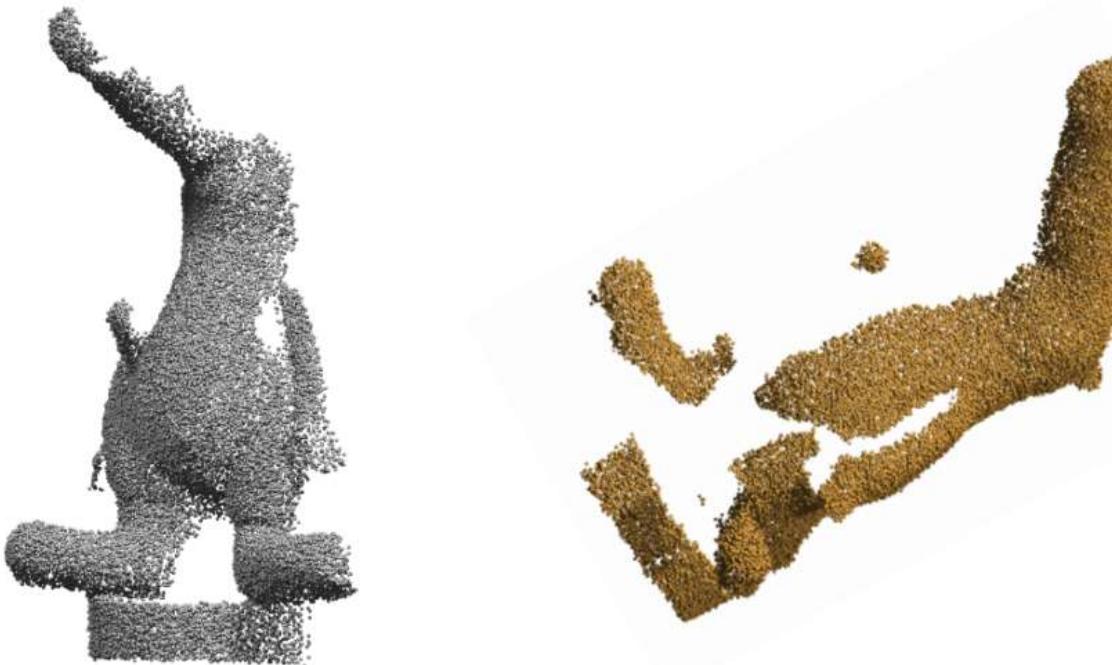
- Refinar la solución con ICP



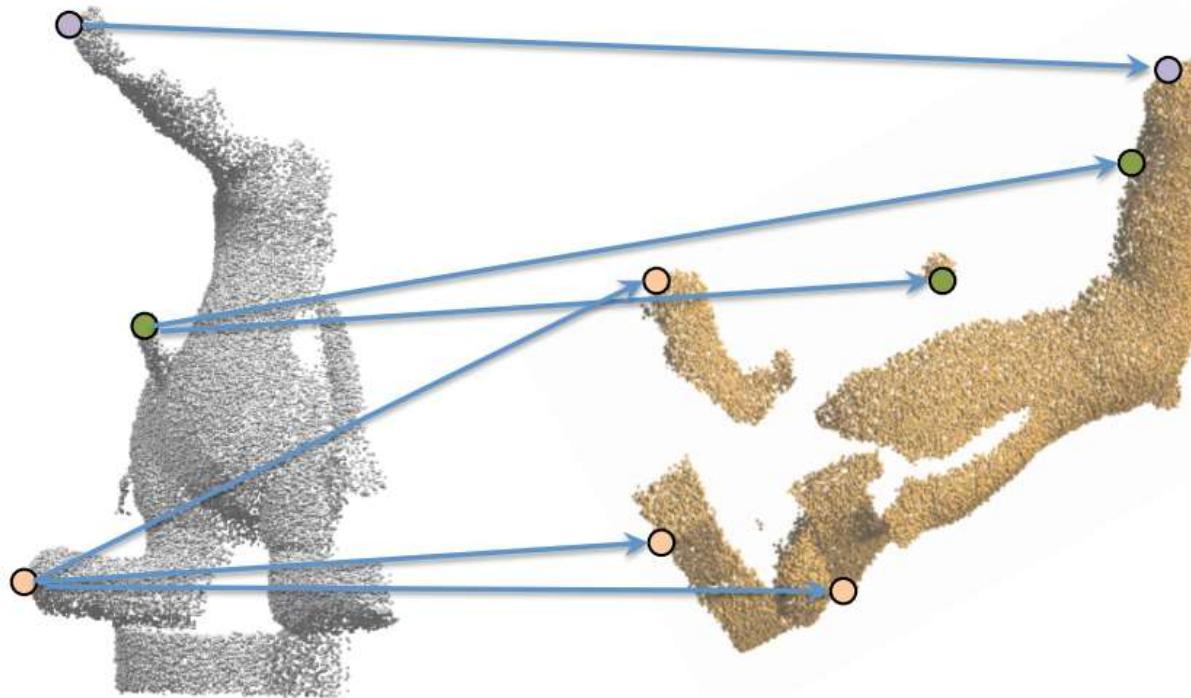
# Métodos Sin Características

## Featureless registration

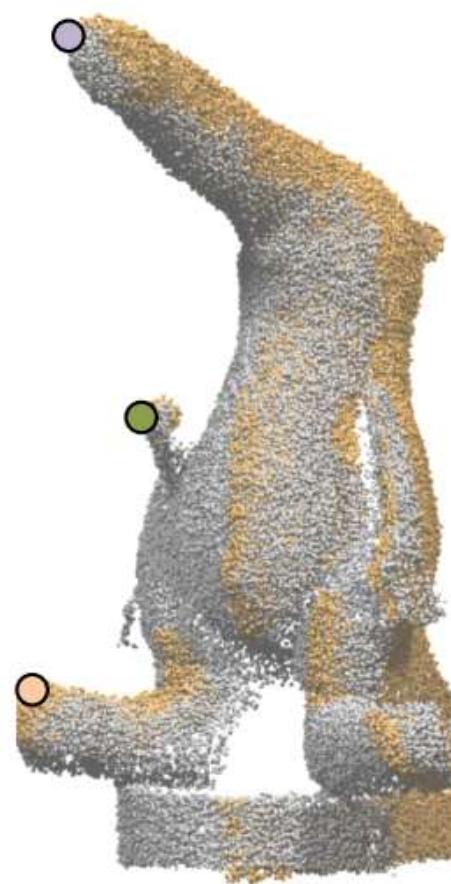
# Alineamiento con puntos de interés



# Alineamiento con puntos de interés



# Alineamiento con puntos de interés

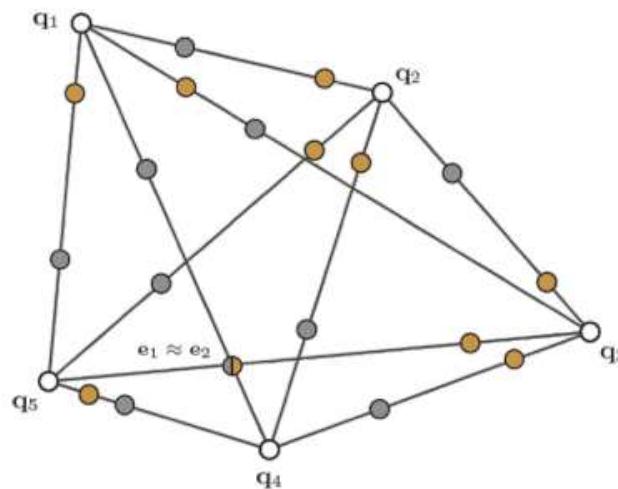


# Ruido, Outliers y Agujeros

- Puntos característicos son generalmente entidades diferenciales
  - Ruido y outliers generan malas correspondencias
  - Una solución son descriptores basados en integrales (no diferenciales)
  - Invariantes integrales
    - Robustos a datos faltantes
- En general, ruido + outliers + agujeros → puntos característicos fallan

# Observación importante

- Un par de tripletas es suficiente para definir una única transformación rígida  $\rightarrow O(n^3)$
- Un conjunto especial de conjuntos congruentes de 4 puntos, se puede resolver en menor complejidad  $\rightarrow O(n^2)$



# Algoritmo 4PCS

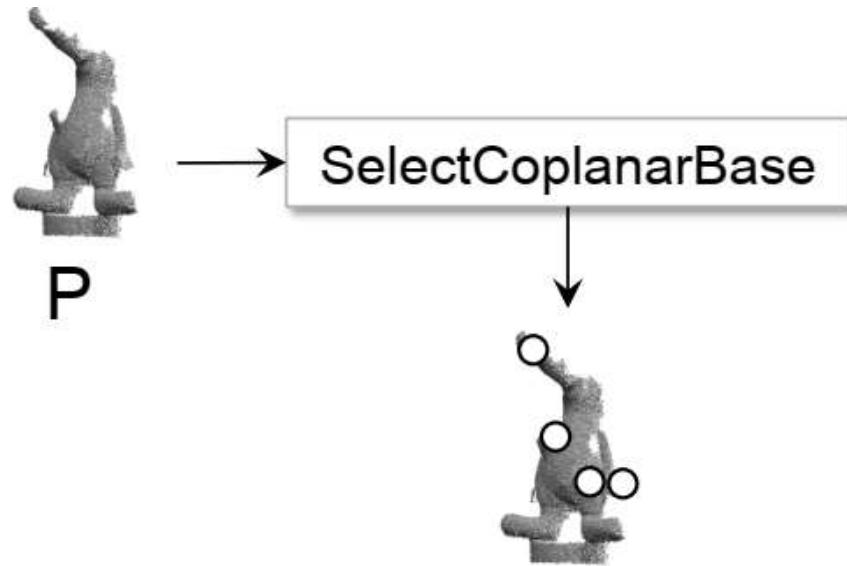


P

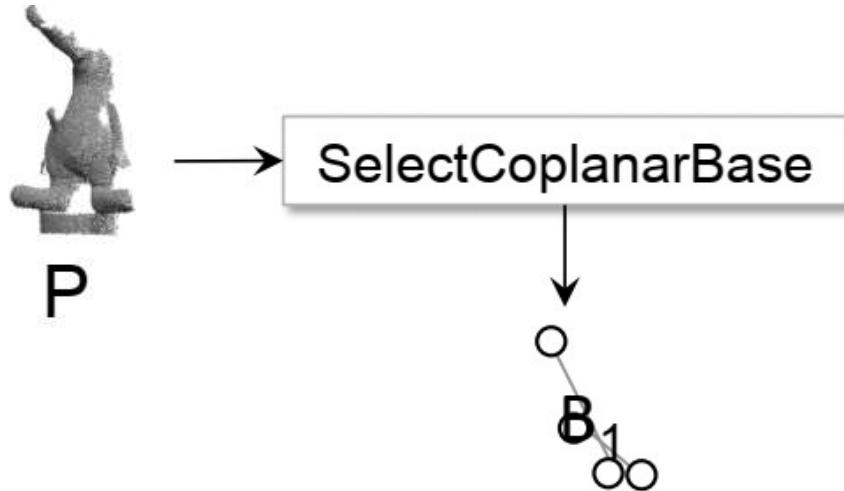


Q

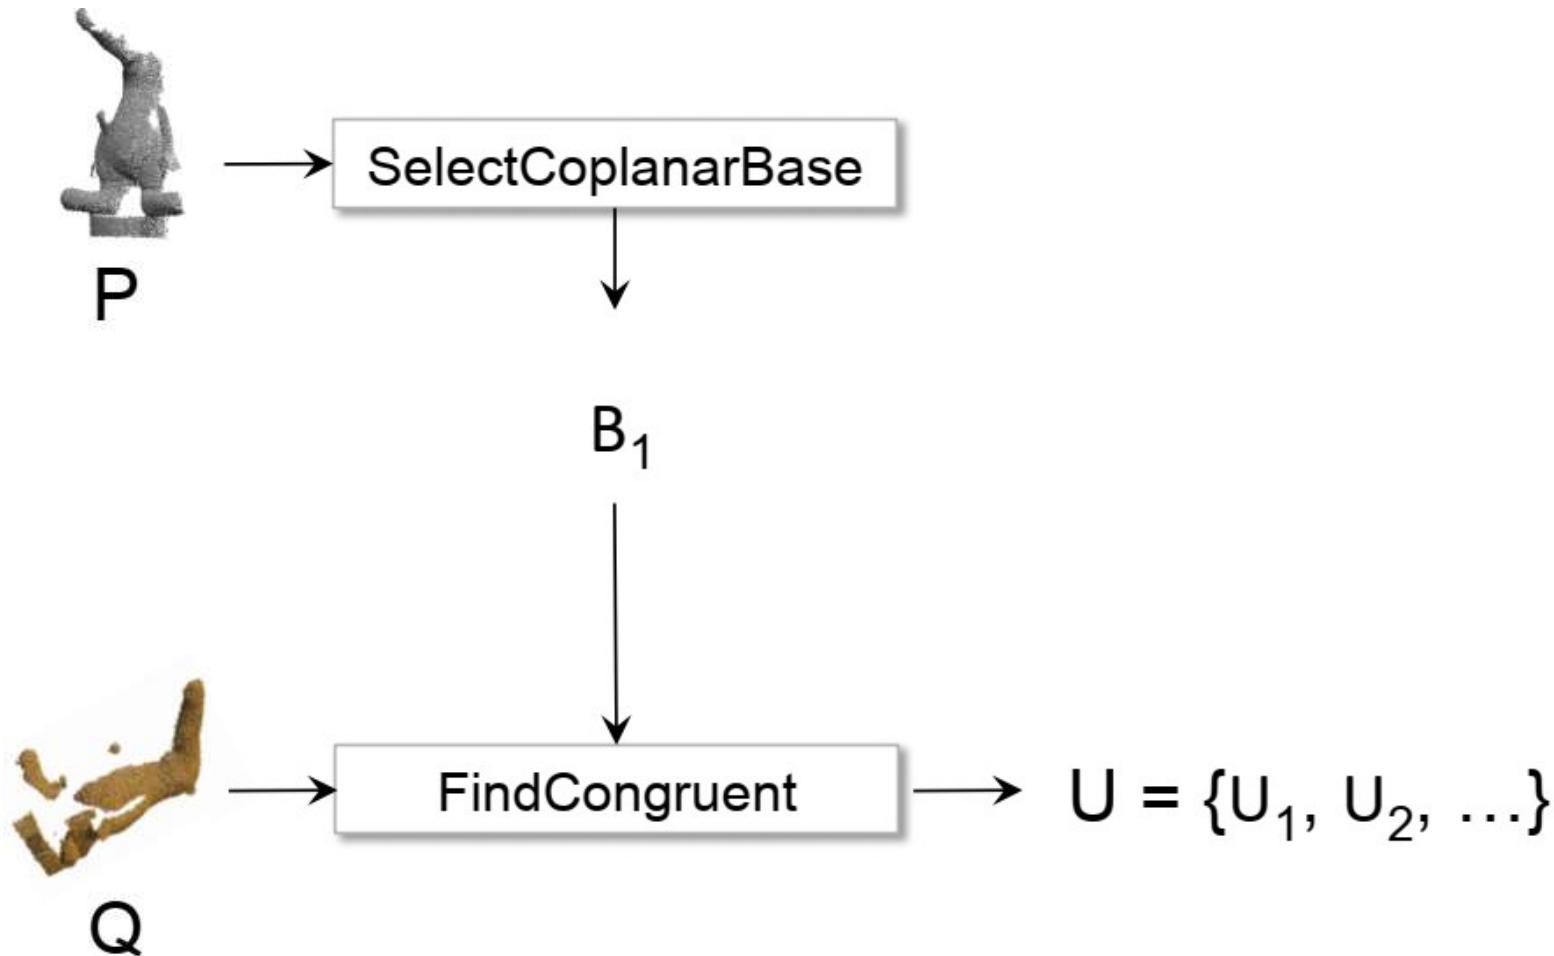
# Algoritmo 4PCS



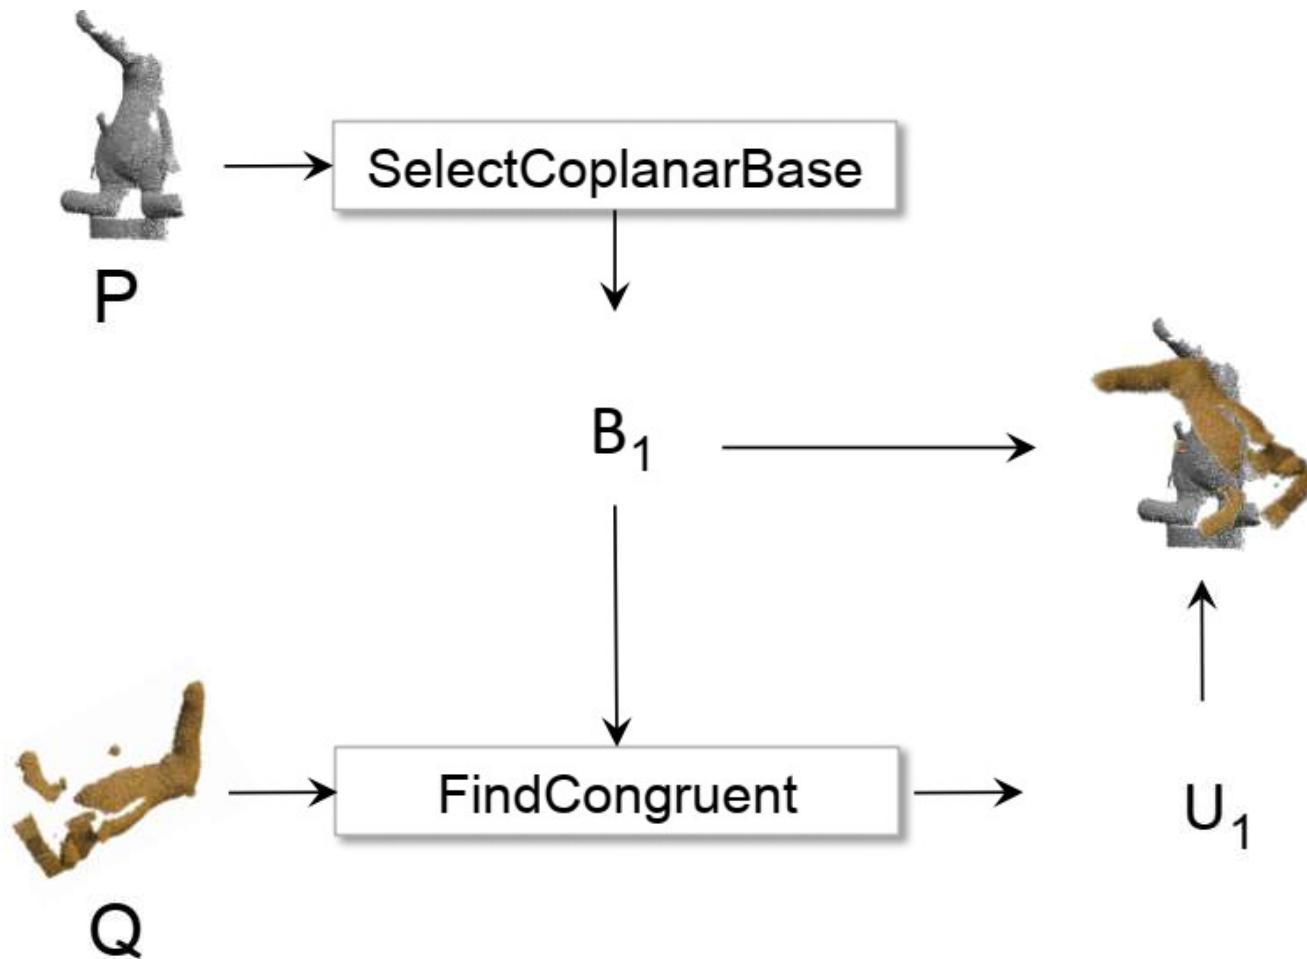
# Algoritmo 4PCS



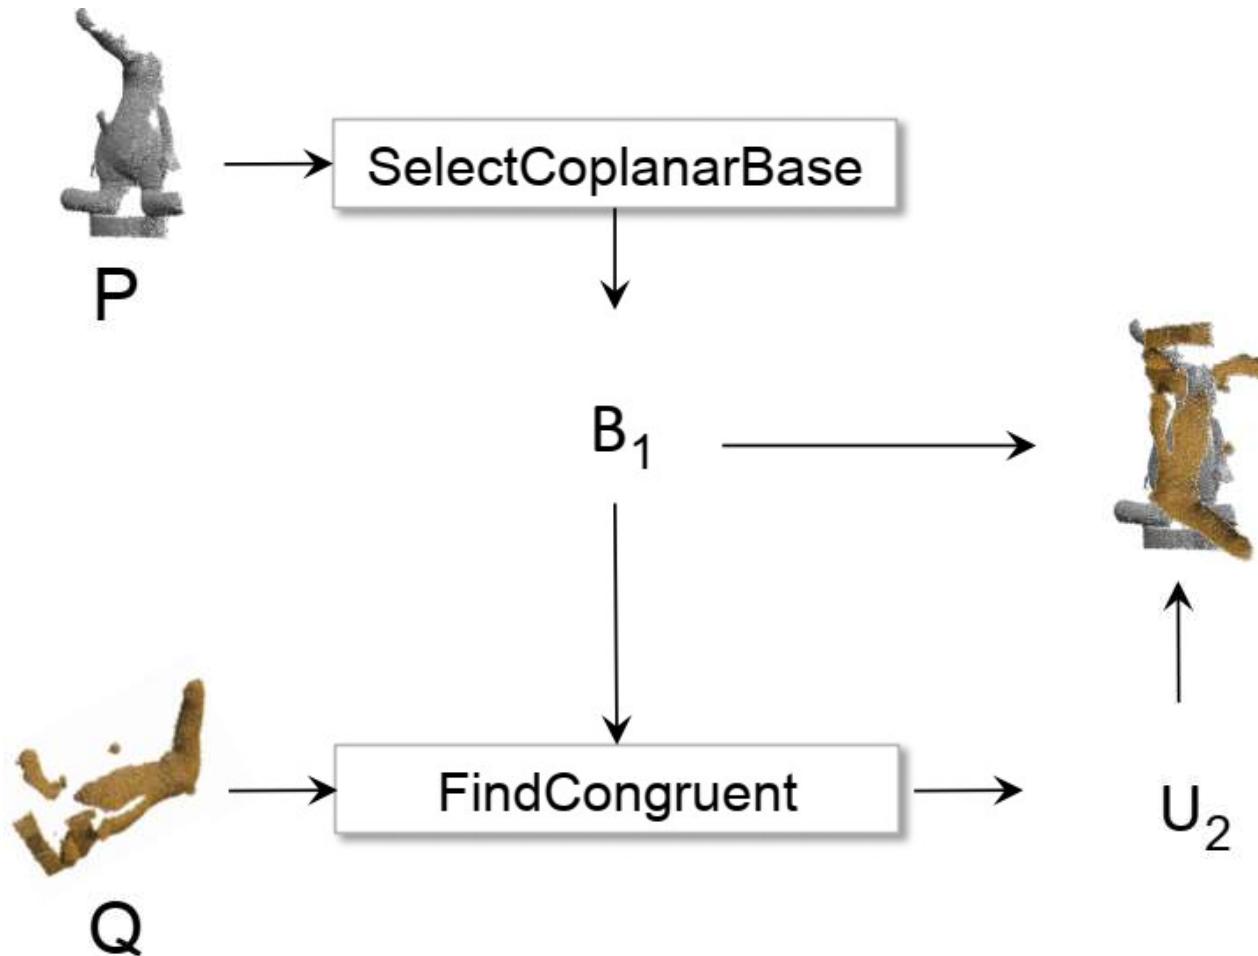
# Algoritmo 4PCS



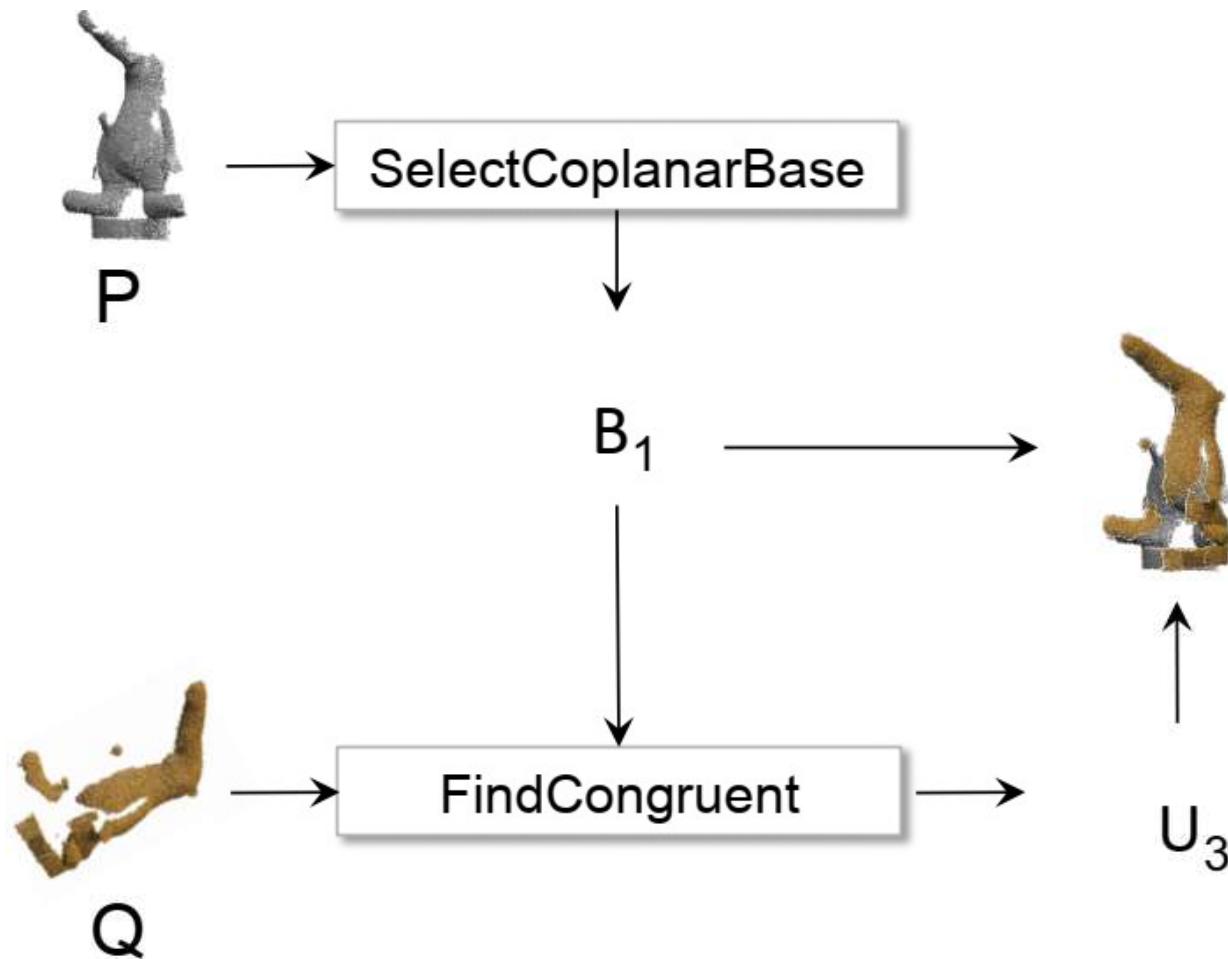
# Algoritmo 4PCS



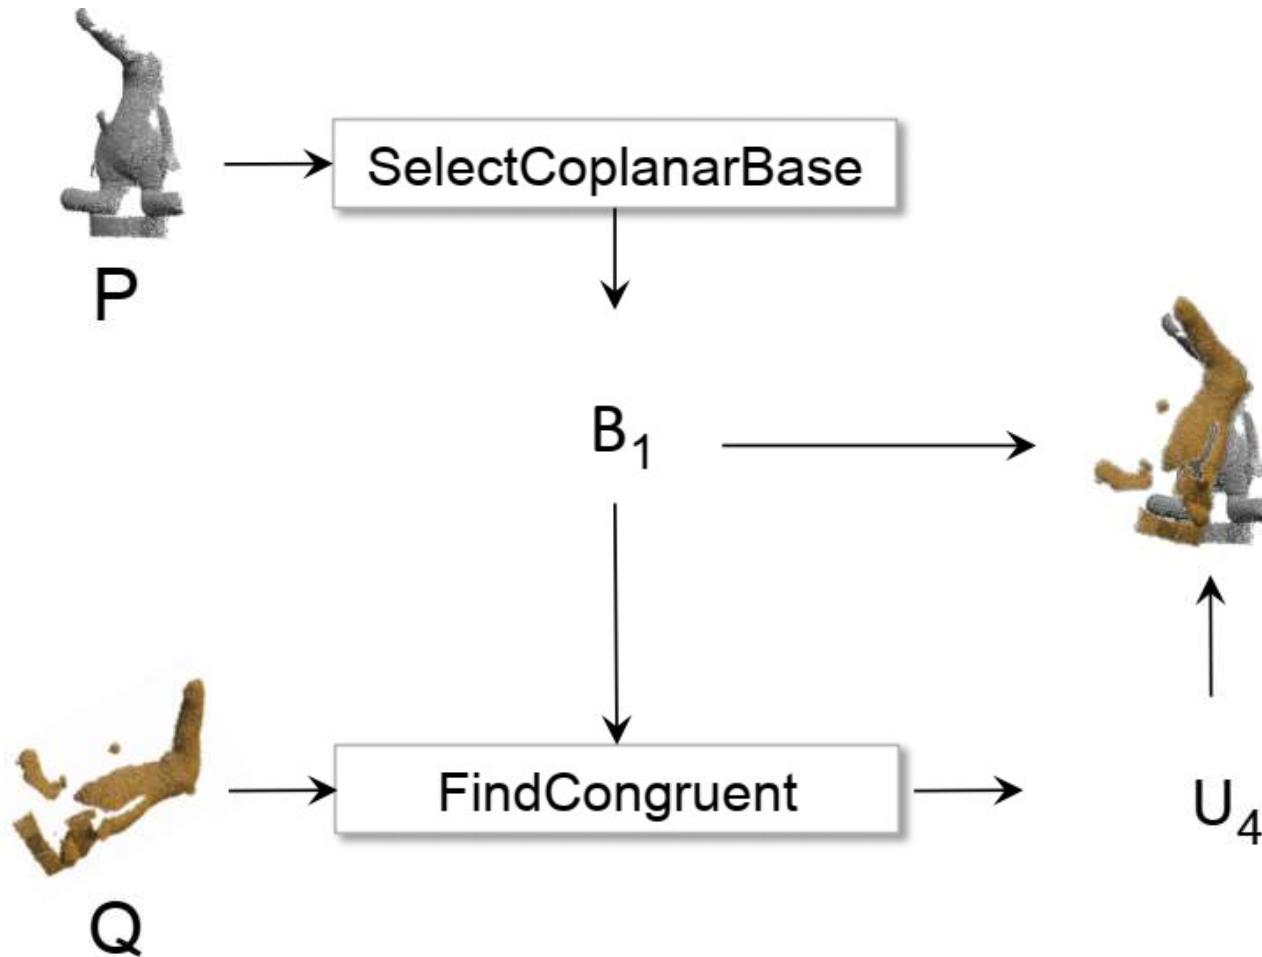
# Algoritmo 4PCS



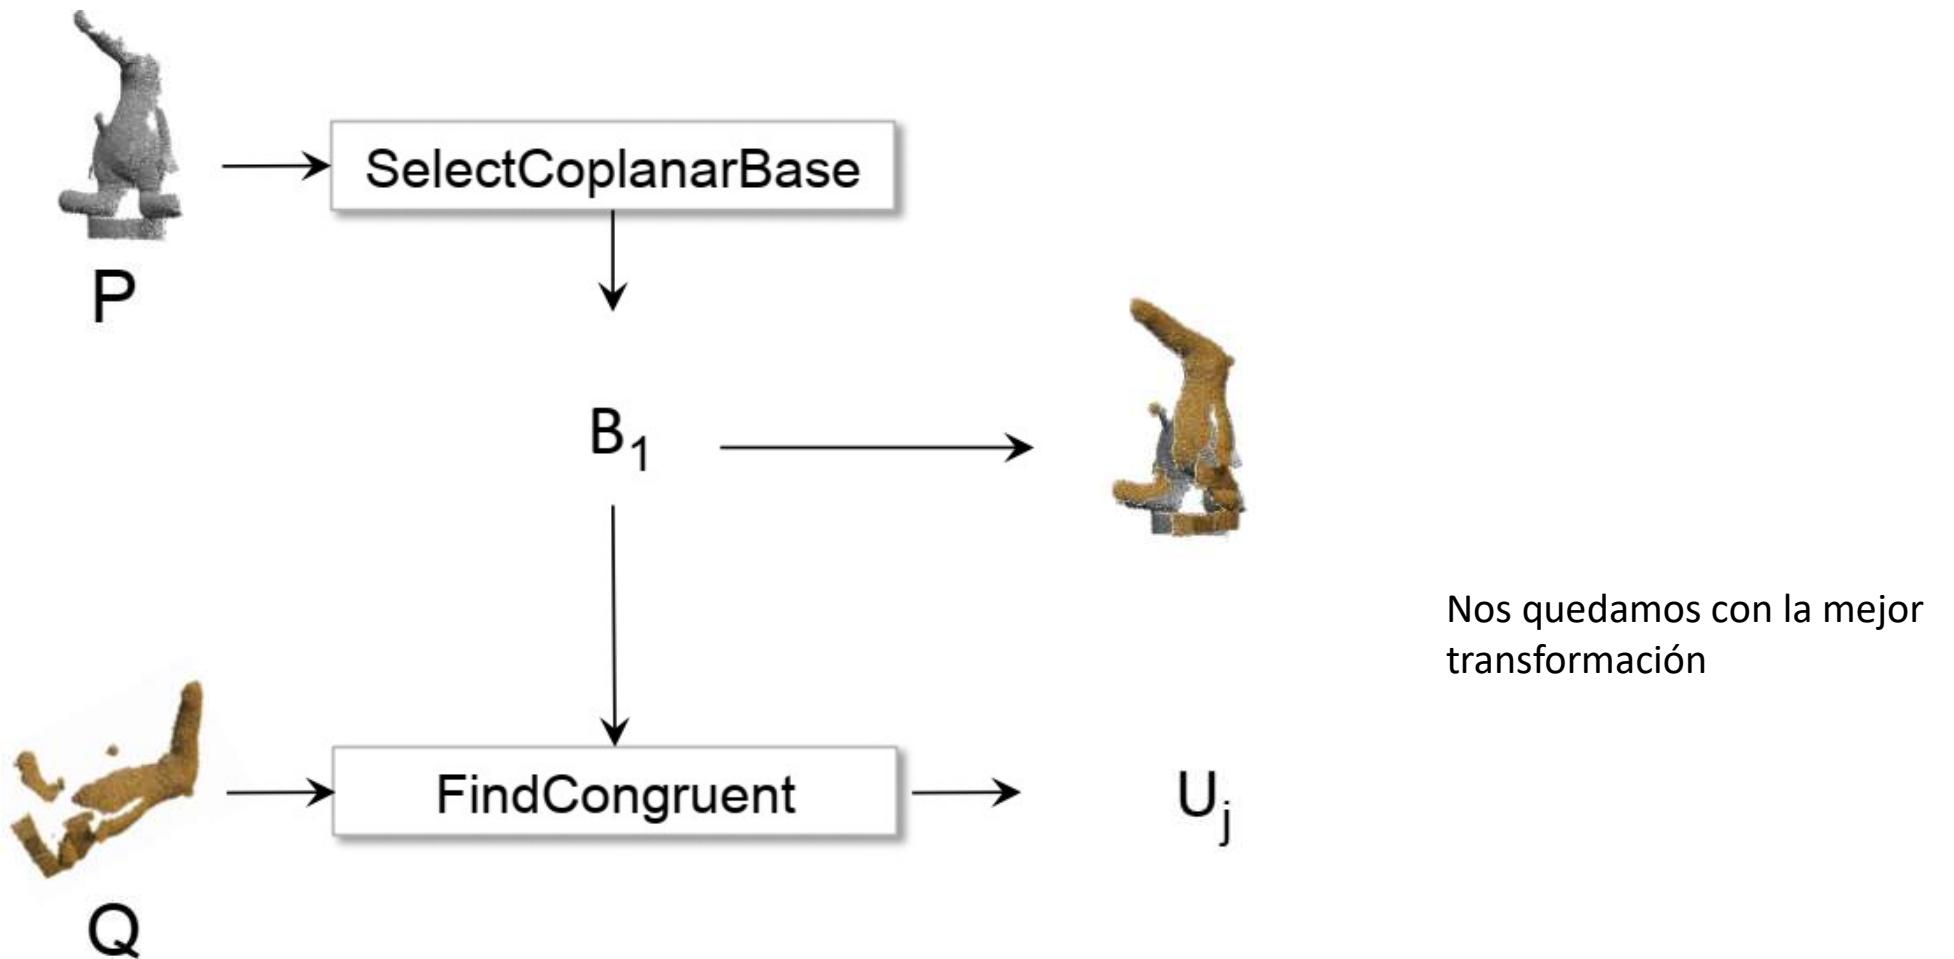
# Algoritmo 4PCS



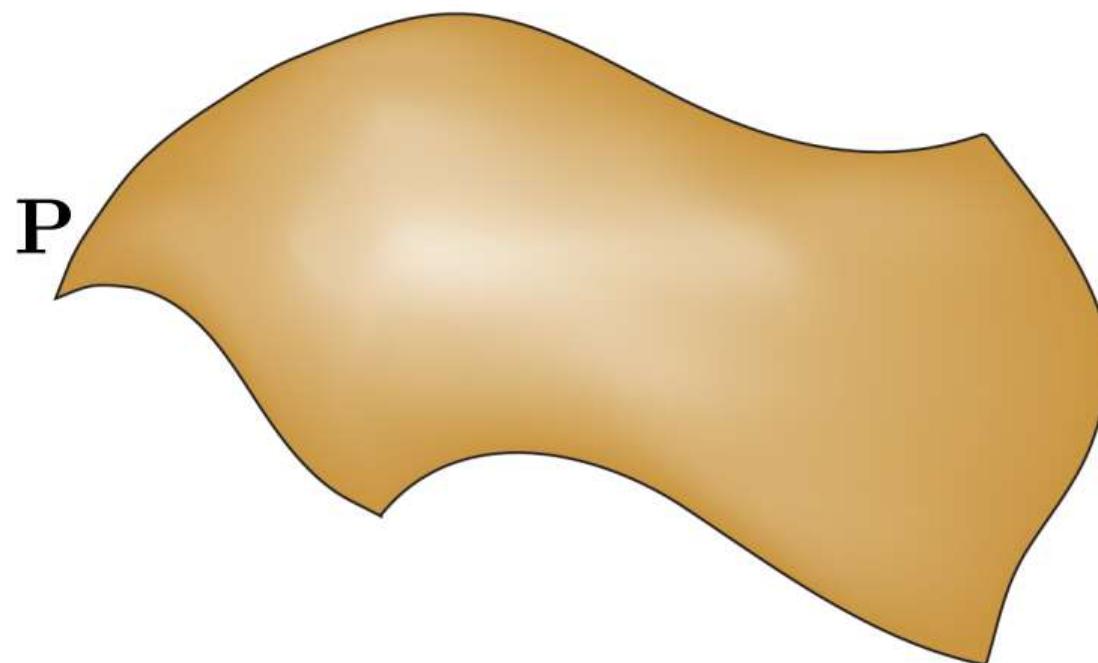
# Algoritmo 4PCS



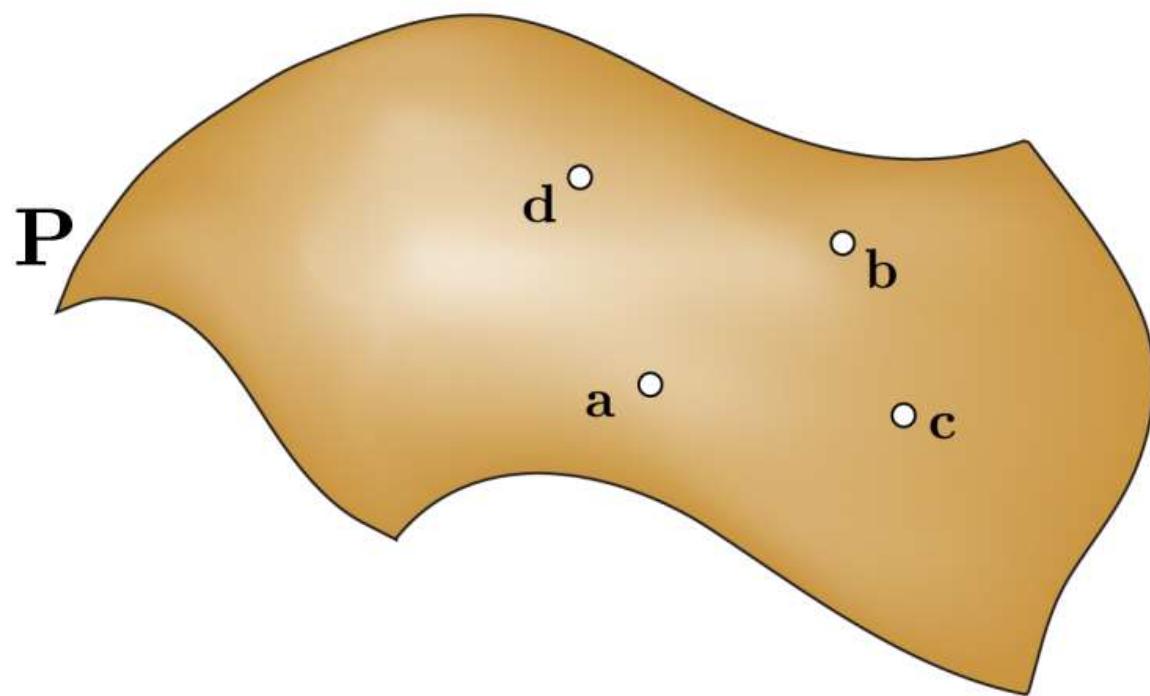
# Algoritmo 4PCS



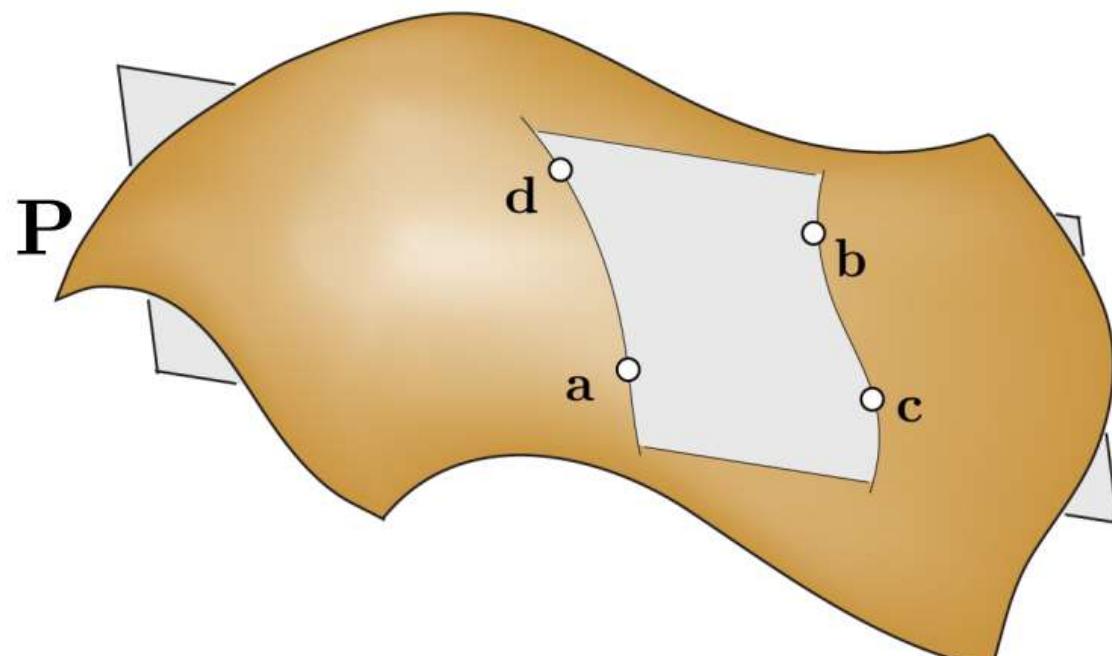
FindCongruent



# FindCongruent

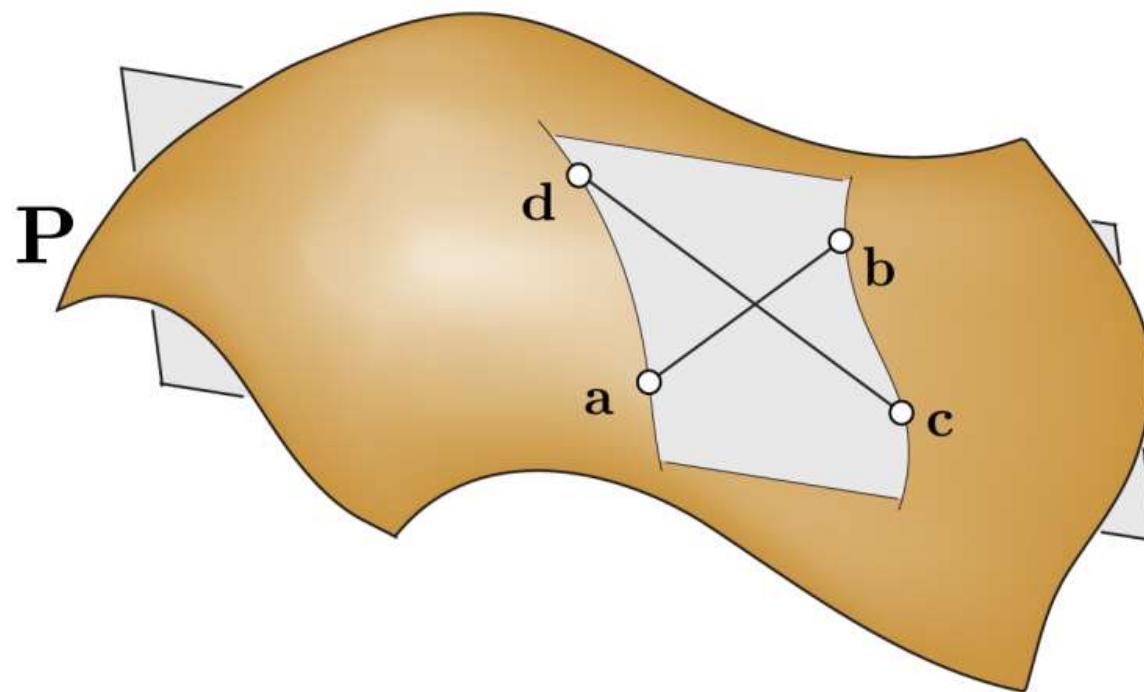


# FindCongruent

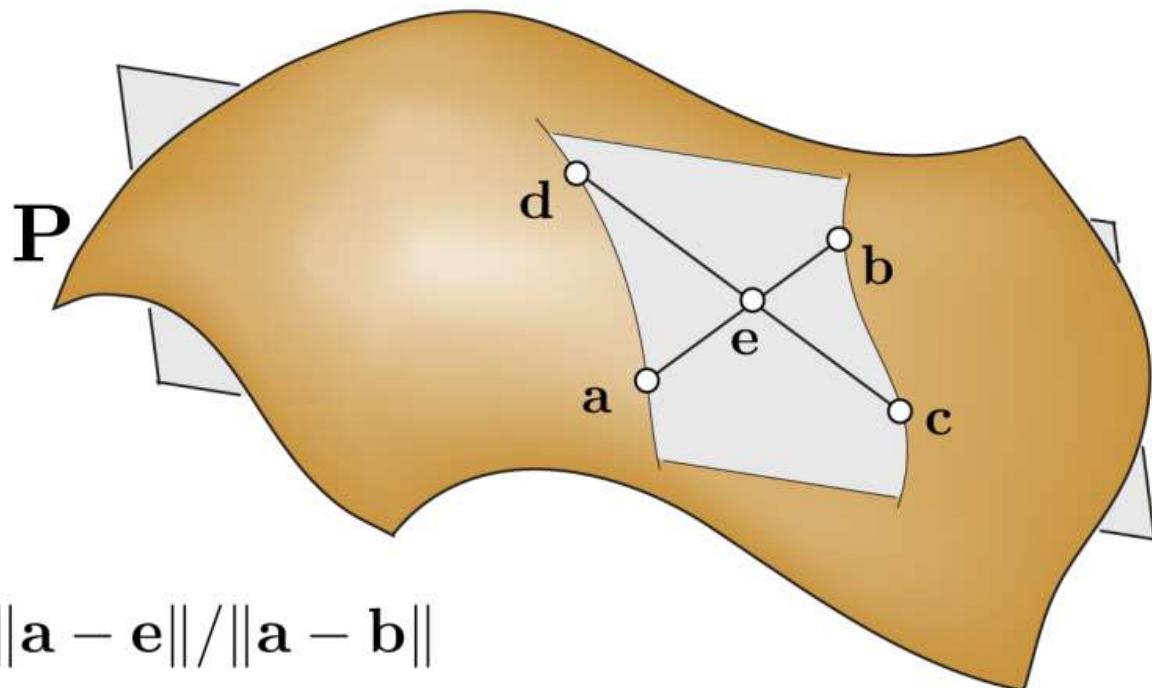


4 coplanar points

# FindCongruent



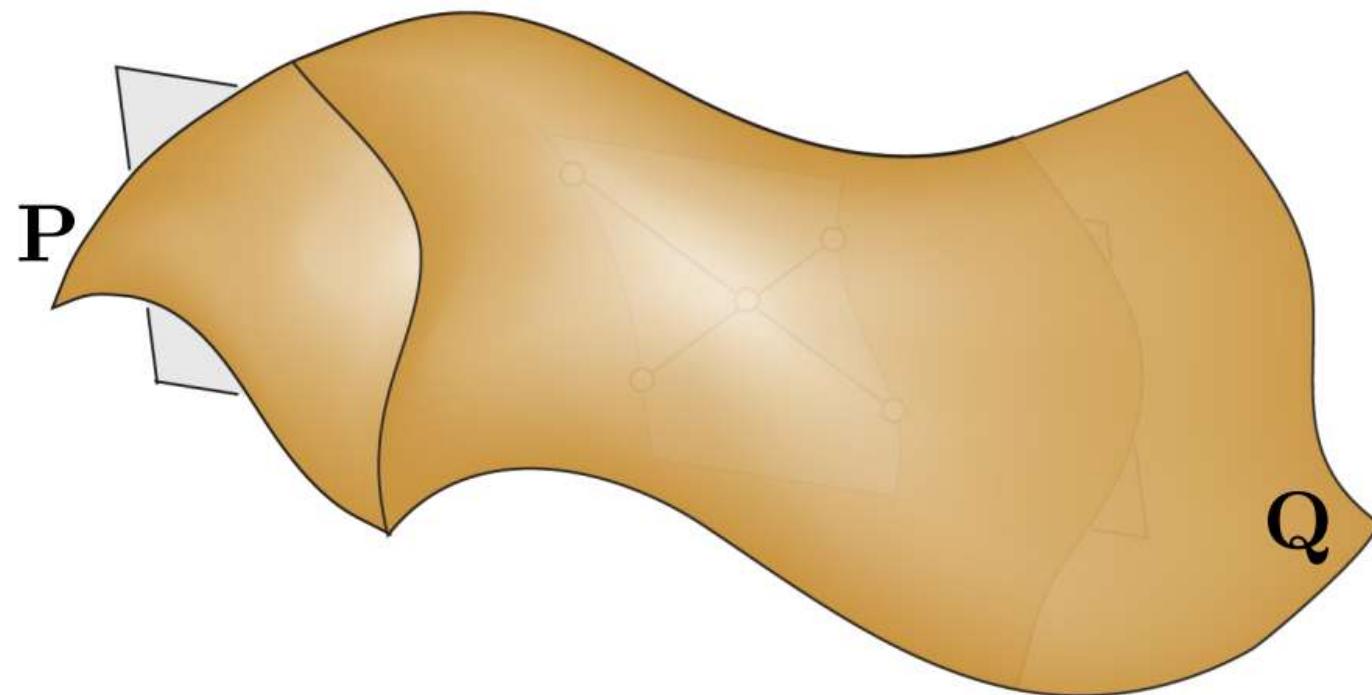
# FindCongruent



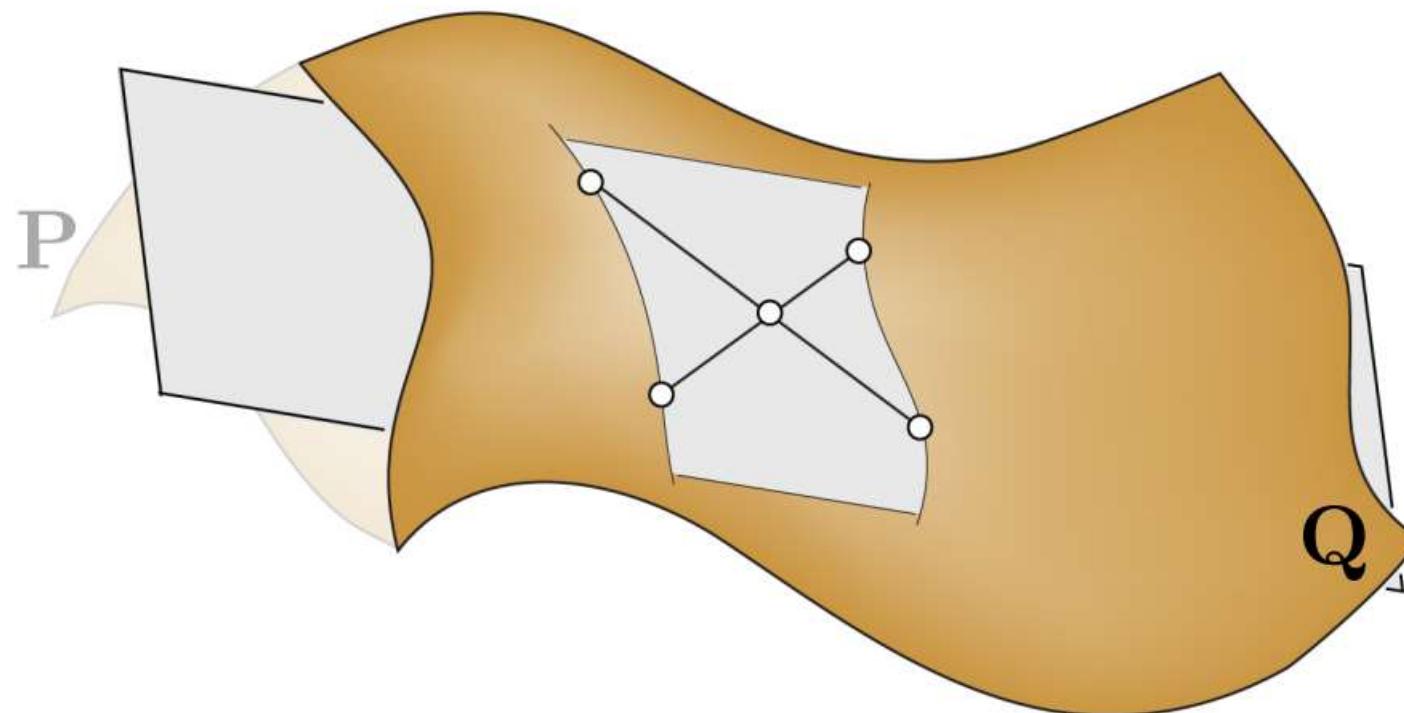
$$r_1 = \|\mathbf{a} - \mathbf{e}\| / \|\mathbf{a} - \mathbf{b}\|$$

$$r_2 = \|\mathbf{c} - \mathbf{e}\| / \|\mathbf{c} - \mathbf{d}\|$$

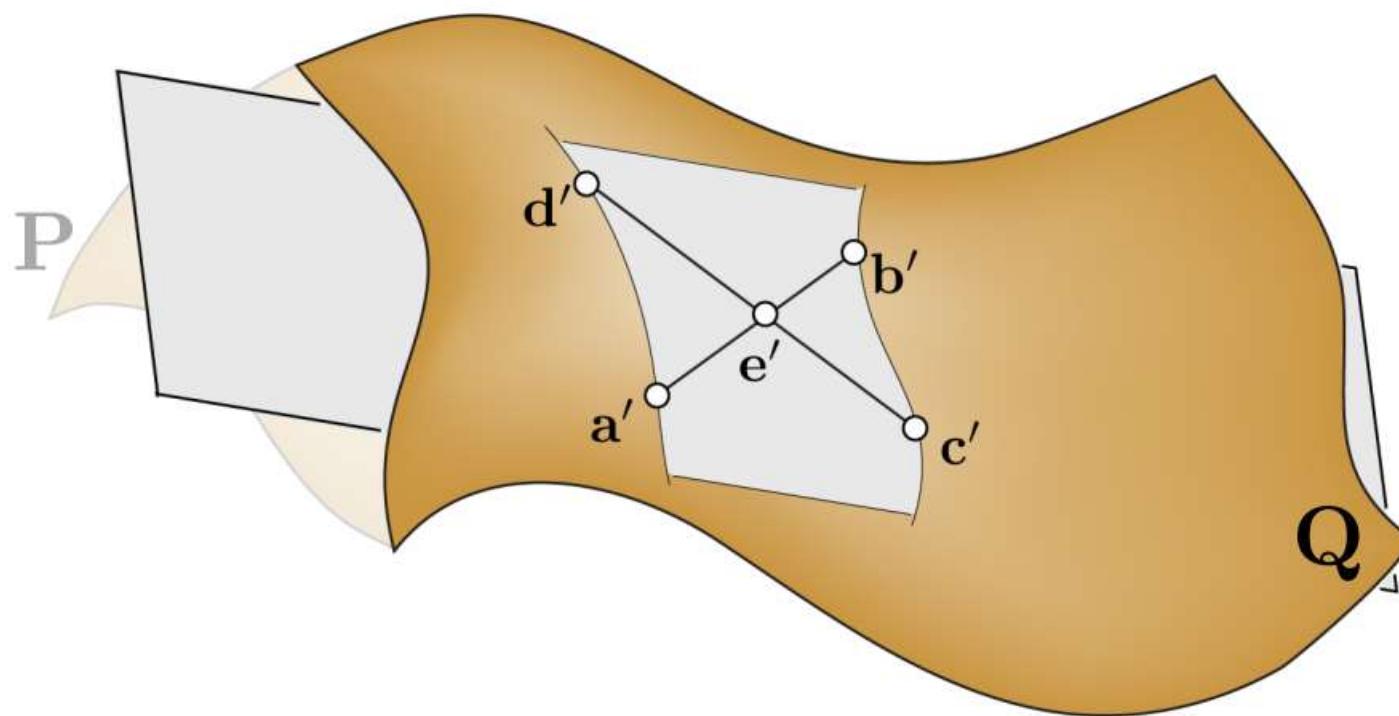
# FindCongruent



# FindCongruent



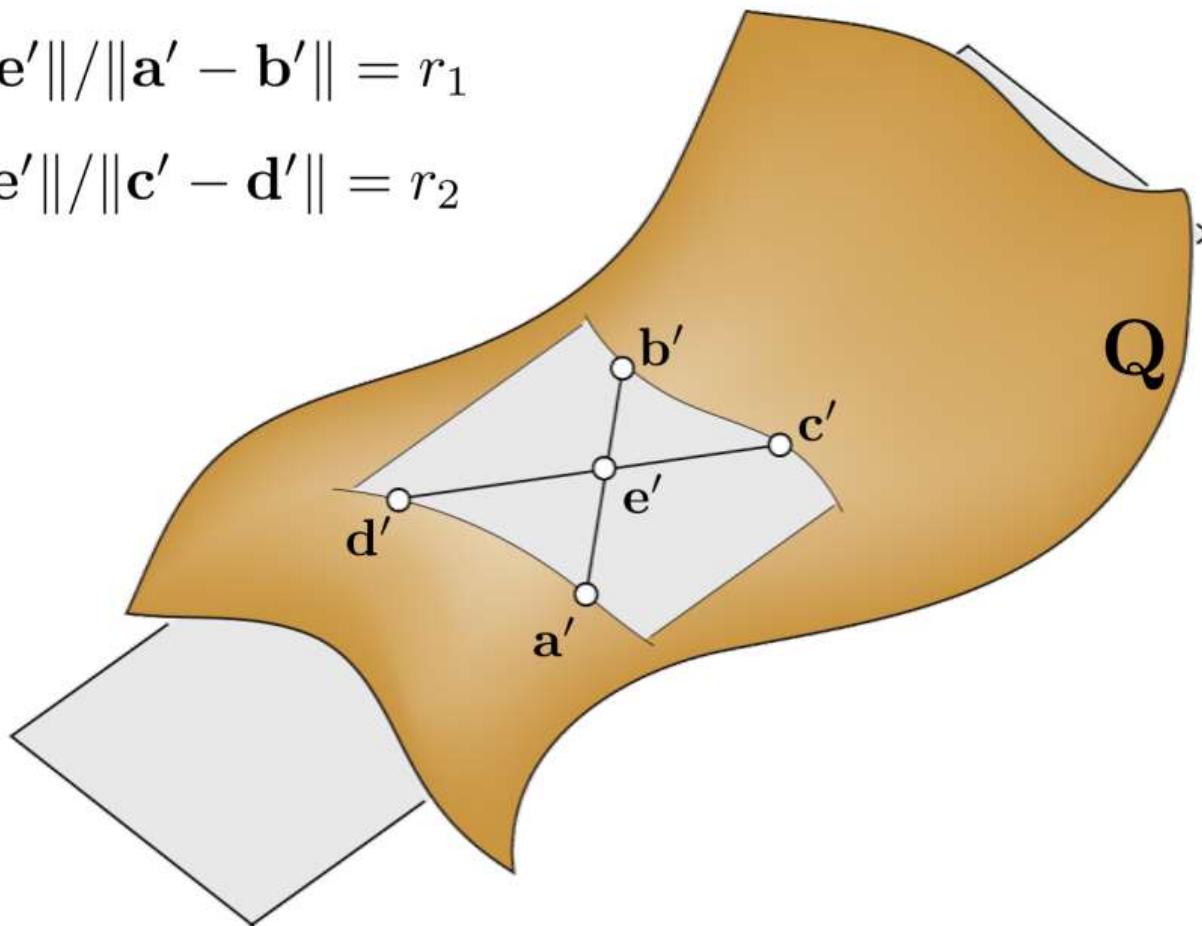
# FindCongruent



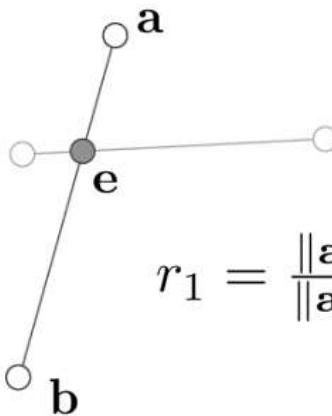
# FindCongruent

$$\|\mathbf{a}' - \mathbf{e}'\| / \|\mathbf{a}' - \mathbf{b}'\| = r_1$$

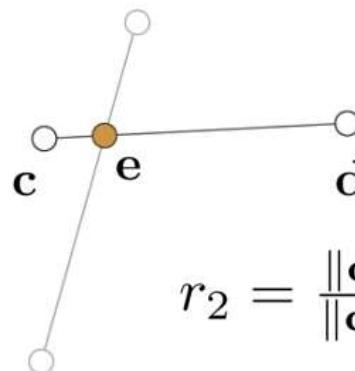
$$\|\mathbf{c}' - \mathbf{e}'\| / \|\mathbf{c}' - \mathbf{d}'\| = r_2$$



# FindCongruent

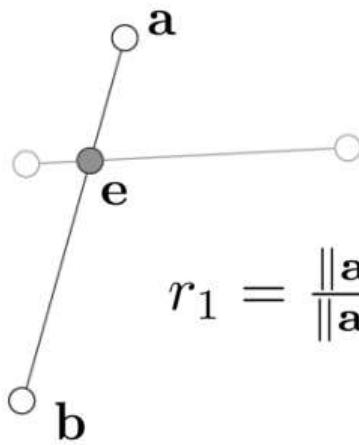


$$r_1 = \frac{\|a-e\|}{\|a-b\|}$$

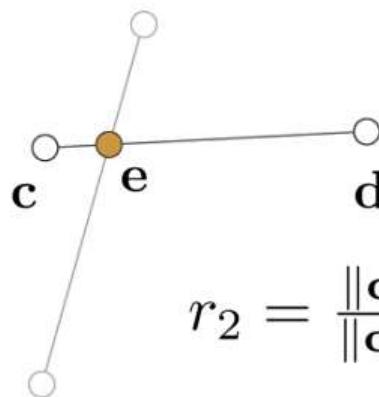


$$r_2 = \frac{\|c-e\|}{\|c-d\|}$$

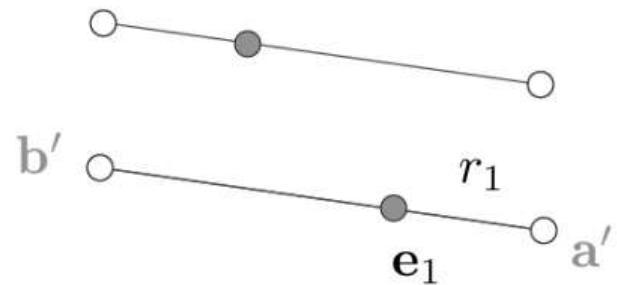
# FindCongruent



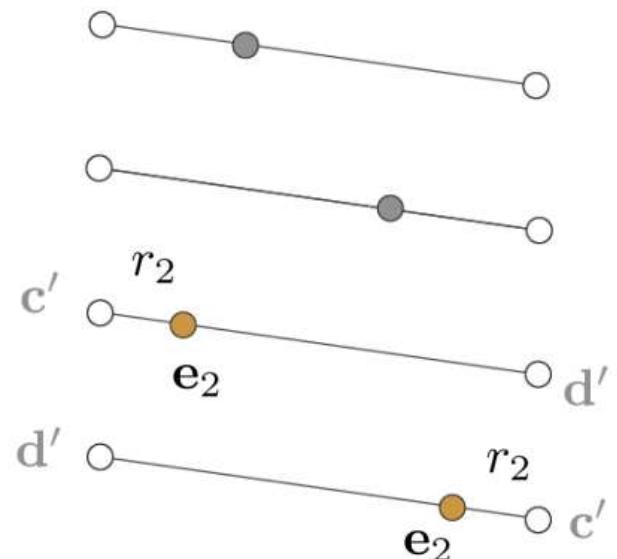
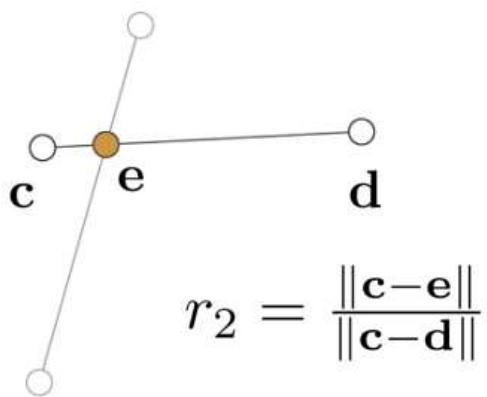
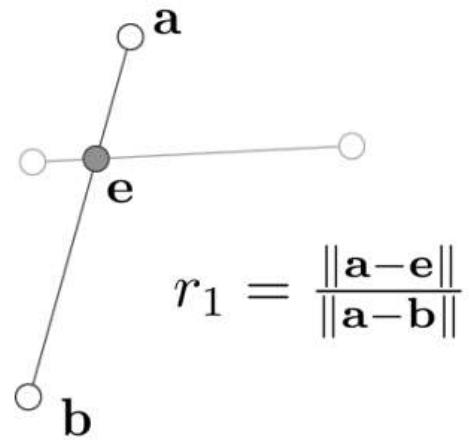
$$r_1 = \frac{\|\mathbf{a}-\mathbf{e}\|}{\|\mathbf{a}-\mathbf{b}\|}$$



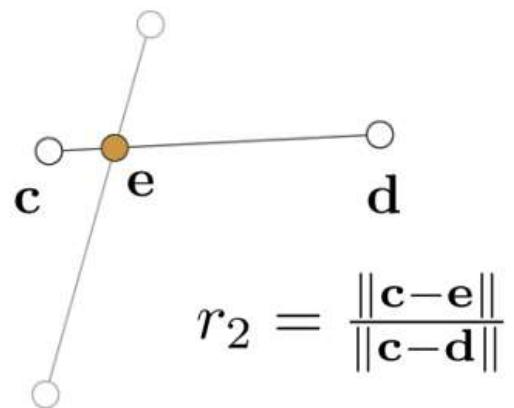
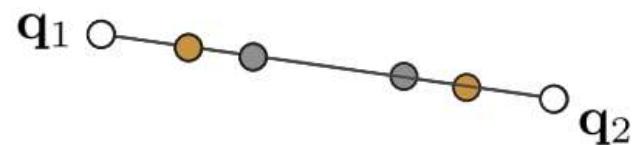
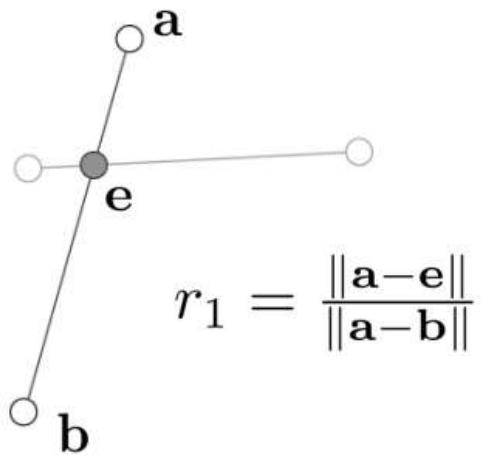
$$r_2 = \frac{\|\mathbf{c}-\mathbf{e}\|}{\|\mathbf{c}-\mathbf{d}\|}$$



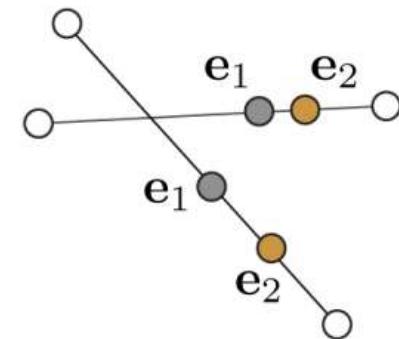
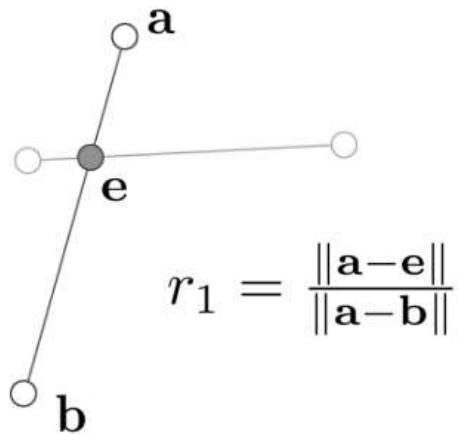
# FindCongruent



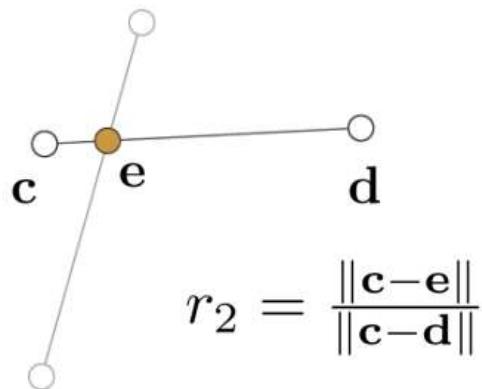
# FindCongruent



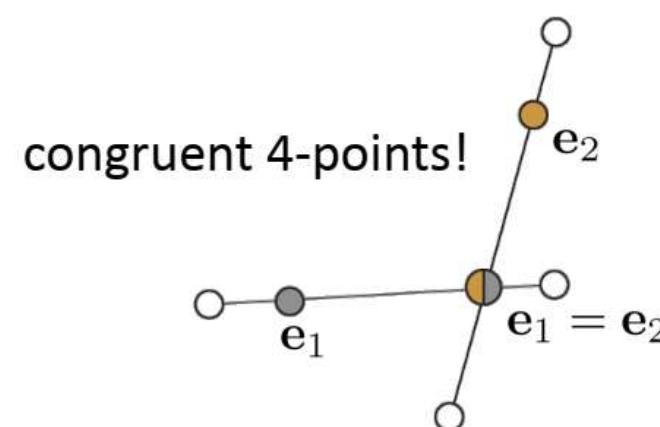
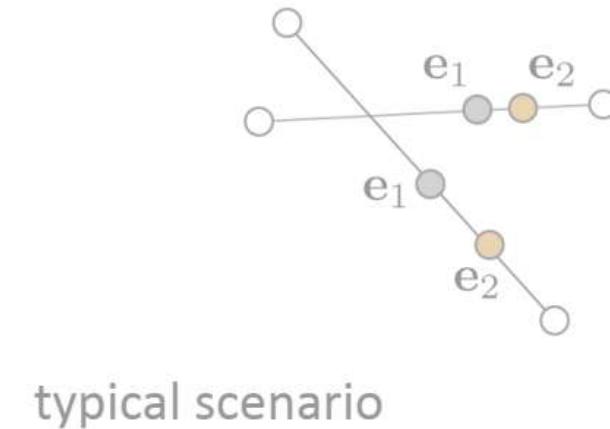
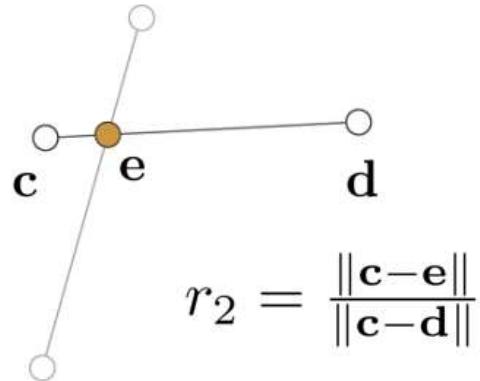
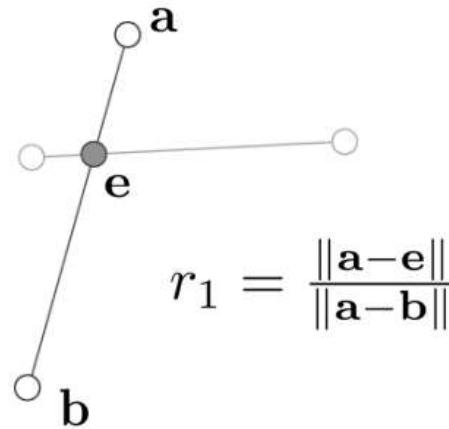
## FindCongruent (cuando $e_1 \neq e_2$ )



typical scenario



# FindCongruent (cuando $e_1 \neq e_2$ )



# Extrayendo 4 puntos congruentes

$\mathbf{q}_1$  ○

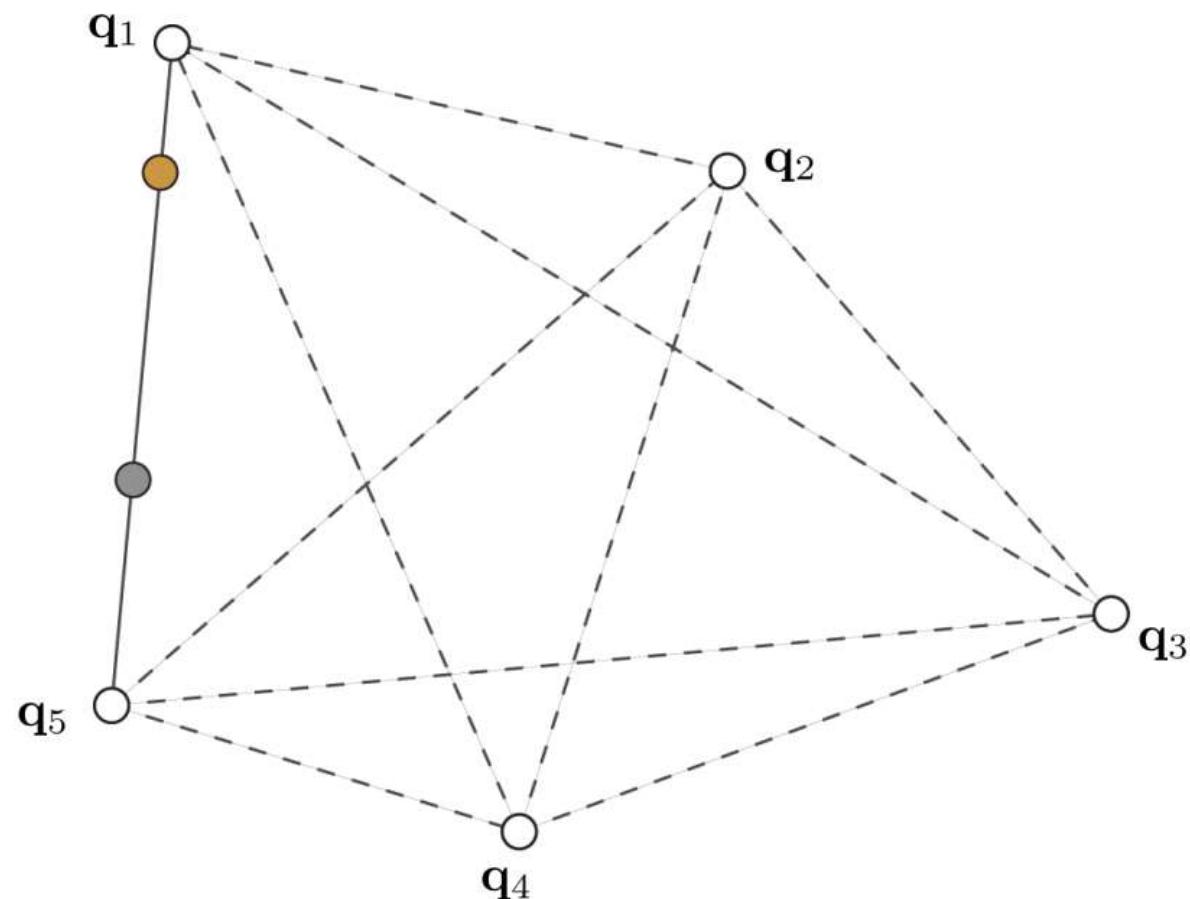
○  $\mathbf{q}_2$

○  $\mathbf{q}_3$

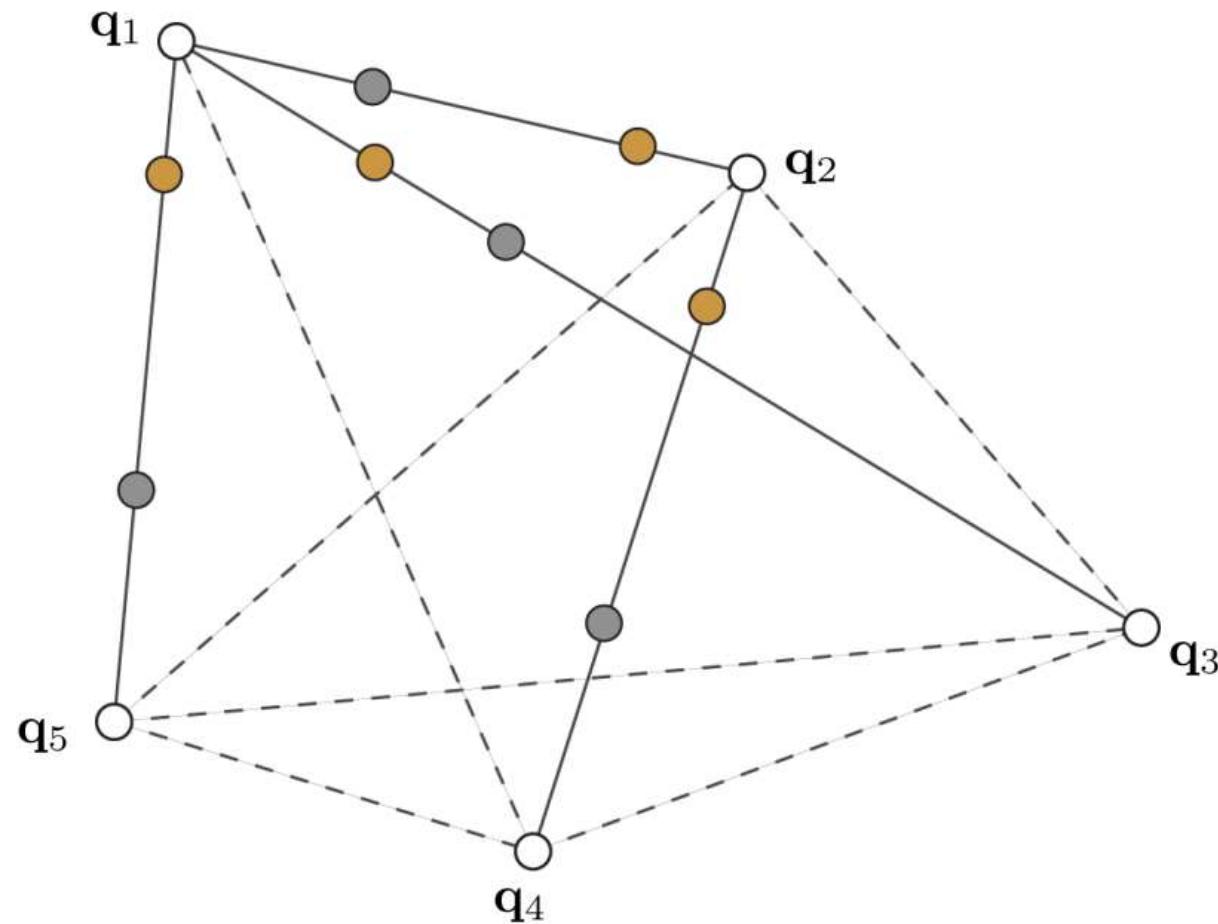
$\mathbf{q}_5$  ○

○  
 $\mathbf{q}_4$

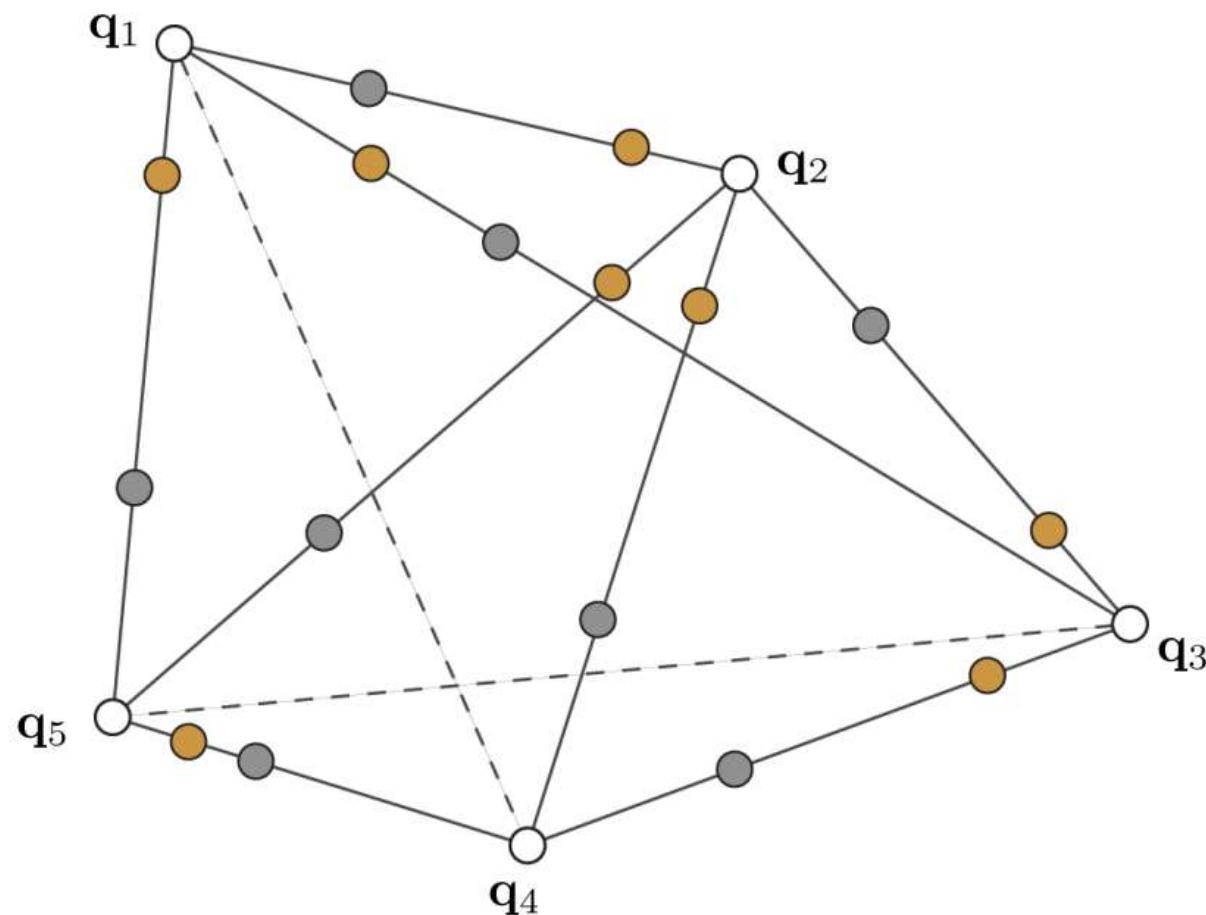
# Extrayendo 4 puntos congruentes



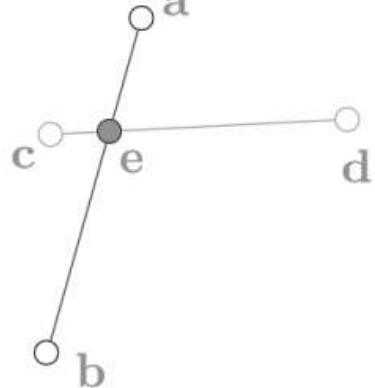
# Extrayendo 4 puntos congruentes



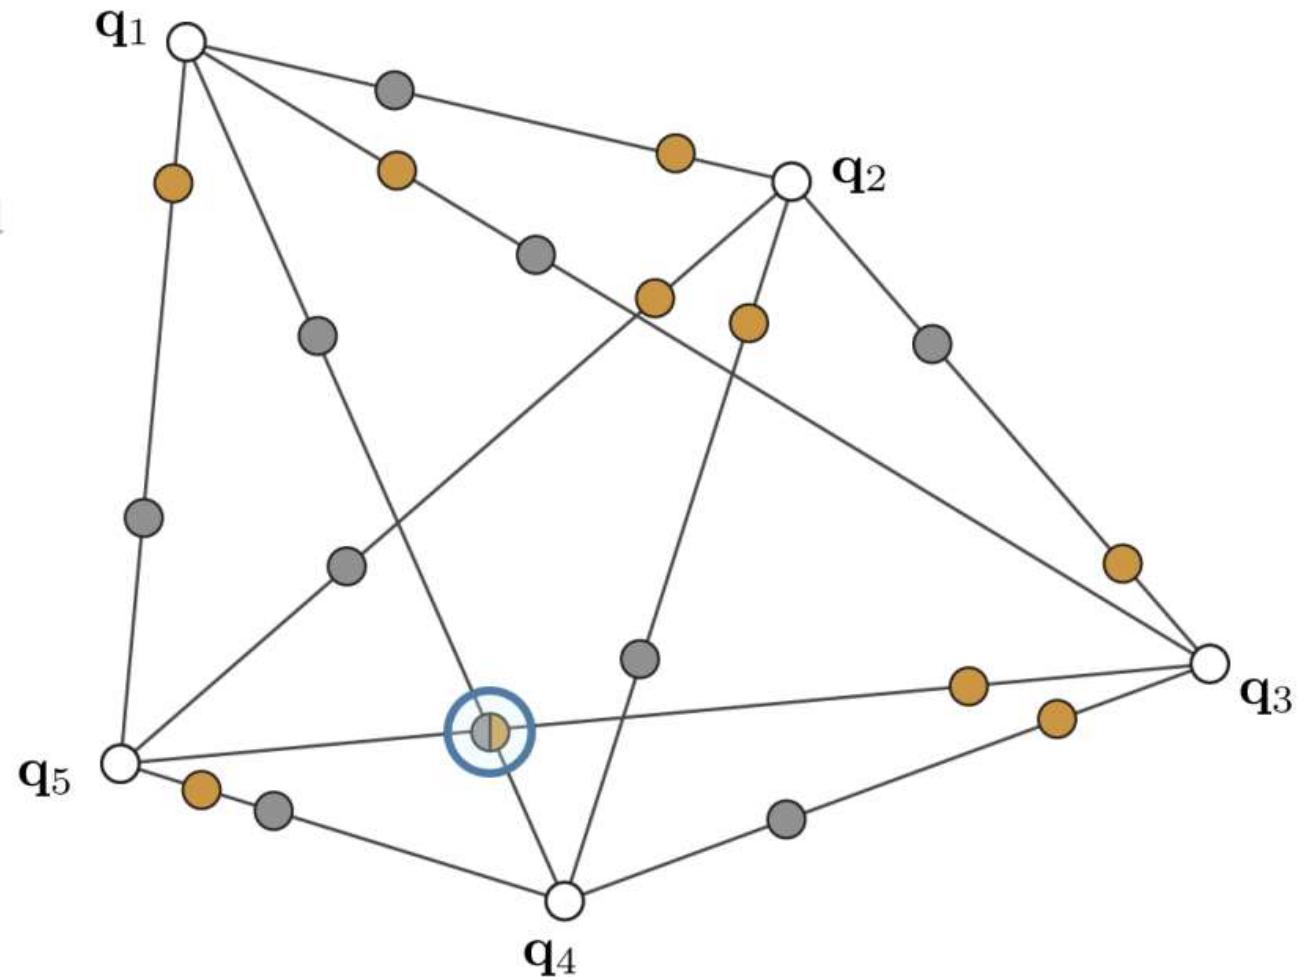
# Extrayendo 4 puntos congruentes



# Extrayendo 4 puntos congruentes



$$\{a, b, c, d\} \equiv \\ \{q_1, q_2, q_3, q_4\}$$



# Resultados

- Ante ruido



$$\sigma = 0.5$$



$$\sigma = 2.0$$



$$\sigma = 4.0$$

